



计算机应用  
*Journal of Computer Applications*  
ISSN 1001-9081, CN 51-1307/TP

## 《计算机应用》网络首发论文

题目：基于大语言模型的双通道融合表示的短文本聚类方法  
作者：王倩飞，李旸，李德玉，王素格  
收稿日期：2025-06-30  
网络首发日期：2025-09-22  
引用格式：王倩飞，李旸，李德玉，王素格. 基于大语言模型的双通道融合表示的短文本聚类方法[J/OL]. 计算机应用.  
<https://link.cnki.net/urlid/51.1307.TP.20250919.1739.006>



**网络首发：**在编辑部工作流程中，稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定，且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式（包括网络呈现版式）排版后的稿件，可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定；学术研究成果具有创新性、科学性和先进性，符合编辑部对刊文的录用要求，不存在学术不端行为及其他侵权行为；稿件内容应基本符合国家有关书刊编辑、出版的技术标准，正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性，录用定稿一经发布，不得修改论文题目、作者、机构名称和学术内容，只可基于编辑规范进行少量文字的修改。

**出版确认：**纸质期刊编辑部通过与《中国学术期刊（光盘版）》电子杂志社有限公司签约，在《中国学术期刊（网络版）》出版传播平台上创办与纸质期刊内容一致的网络版，以单篇或整期出版形式，在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊（网络版）》是国家新闻出版广电总局批准的网络连续型出版物（ISSN 2096-4188，CN 11-6037/Z），所以签约期刊的网络版上网络首发论文视为正式出版。

# 基于大语言模型的双通道融合表示的短文本聚类方法

王倩飞<sup>1</sup>, 李旻<sup>2\*</sup>, 李德玉<sup>1,3</sup>, 王素格<sup>1,3</sup>

(1.山西大学 计算机与信息技术学院, 山西 太原 03006;

2.山西财经大学 金融学院, 山西 太原 03006;

3.山西大学 计算智能与中文信息处理教育部重点实验室, 山西 太原 03006)

(\*通信作者电子邮箱 liyang@sxufe.edu.cn)

**摘要:** 针对当前短文本聚类中全局语义表示不足和局部区分性弱等问题, 提出一种基于大语言模型的双通道融合表示短文本聚类方法。该方法从全局视角, 建立基于语义增强的伪标签对比学习模块, 利用大语言模型生成关键词短语并与原始文本动态加权融合增强语义表示, 进一步利用自适应最优传输生成高置信度伪标签, 结合类内紧密度与类间可分性约束, 采用端到端的训练方式, 建立全局语义一致的向量表示; 从局部视角, 建立基于熵差异的三元表示优化模块, 通过熵差异度量筛选高信息量样本, 再利用置信度加权损失与去噪机制微调嵌入模型, 生成局部判别性强的向量表示。最终, 建立基于自注意力机制的全局与局部信息融合语义表示, 并直接用于聚类算法中。在 8 个公开短文本聚类数据集上, 本文方法与主流基线进行对比实验。实验结果验证了所提方法在所有数据集的 ACC 指标均优于基线, 平均提升 1.85%, 其中在 GoogleNews-T 上最高提升 3.19%; 在聚类一致性(NMI)指标上, 6 个数据集优于基线, 平均提升 1.53%, 其中在 SearchSnippets 上最高提升 3.46%。实验结果表明该方法适应于多场景下的聚类任务。

**关键词:** 大语言模型; 短文本聚类; 全局语义增强; 局部判别优化; 自注意力机制

**中图分类号:** TP391

**文献标志码:** A

## Dual-channel fusion representation method for short text clustering based on large language model

Wang Qianfei<sup>1</sup>, Li Yang<sup>2\*</sup>, Li Deyu<sup>1,3</sup>, Wang Suge<sup>1,3</sup>

(1. School of Computer & Information Technology, Shanxi University, Taiyuan Shanxi 030006, China;

2. School of Finance, Shanxi University of Finance and Economics, Taiyuan Shanxi 030006, China;

3. Key Laboratory of Computational Intelligence and Chinese Information Processing of Ministry of Education, Shanxi University, Taiyuan Shanxi 030006, China)

**Abstract:** To address the problems of insufficient global semantic representation and weak local discriminability in current short text clustering, a dual-channel fusion representation method for short text clustering based on large language models is proposed. From the global perspective, a semantic-enhanced pseudo-label contrastive learning module was established. Keyword phrases generated by LLMs were dynamically weighted and fused with original texts to enrich representations. High-confidence pseudo-labels were produced via adaptive optimal transport, while cluster compactness and separation constraints were integrated into end-to-end training to achieve globally consistent embeddings. From the local perspective, an entropy-difference-based triplet refinement module was designed. High-information samples were selected by entropy difference metrics, Then the embedding model is fine-tuned by using the confidence weighted loss and denoising mechanism to generate a vector representation with strong local discrimination. Finally, the global and local representations were fused using self-attention mechanisms for direct clustering. The proposed method was compared with the mainstream baselines on eight public short text clustering datasets. The experimental results showed that the proposed method surpassed the baselines in accuracy (ACC) on all datasets, achieving an average improvement of 1.85%, with the highest improvement of 3.19% observed on GoogleNews-T. In clustering consistency (NMI), the proposed method outperformed the baseline methods on six datasets, with an average improvement of 1.53% and the highest improvement of 3.46% on SearchSnippets. The experimental results demonstrate that the proposed method consistently adapts to clustering tasks across diverse scenarios.

收稿日期: 2025-06-30; 修回日期: 2025-07-23; 录用日期: 2025-07-31。

基金项目: 国家自然科学基金项目(62473241, 62376143)。

**作者简介:** 王倩飞(1999—), 男, 山西运城, 硕士研究生, 主要研究方向: 数据挖掘; 李旻(1988—), 女, 山西曲沃, 副教授, 博士, 是 CCF 会员, 主要研究方向: 智能金融、自然语言处理; 李德玉(1965—), 男, 山西曲沃, 教授, 博士, 是 CCF 会员, 主要研究方向: 数据挖掘; 王素格(1964—), 女, 河北定州, 教授, 博士, 是 CCF 会员, 主要研究方向: 自然语言处理、文本挖掘、情感分析。

**Keywords:** Large Language Model; Short Text Clustering; Global Semantic Enhancement; Local Discriminative Optimization; Self-Attention Mechanism

## 0 引言

随着社交媒体和在线新闻平台的发展,短文本广泛应用于新闻报道、社交动态、用户评论和在线问答等场景。短文本聚类作为一种无监督学习任务,旨在发现文本的潜在结构,将语义相似的内容归为一类,在信息检索、推荐系统<sup>[1]</sup>、观点挖掘<sup>[2]</sup>和立场检测<sup>[3]</sup>等领域具有重要价值。

短文本通常缺乏上下文,导致语义表达不完整。例如,“苹果发布新品”可能指科技公司的新品发布,也可能指农业中的新苹果品种。此外,即使在相同领域,不同表达方式也可能存在较大差异,如“降价促销”与“价格优惠”传达相似含义,但传统词匹配方法难以识别其语义一致性。这些挑战影响了基于词频或统计特征的传统方法,使得短文本聚类任务更加复杂。近年来,预训练模型<sup>[4-6]</sup>凭借强大的文本编码能力,为短文本聚类提供了新的解决方案。通过自监督学习,模型能够捕捉更丰富的语义信息,使相似性计算更精准。然而,通用的预训练模型主要针对长文本优化,在短文本上的表现仍受限,难以准确建模句子之间的细粒度语义差异。为了提升短文本的表示能力,研究者提出了多种优化策略。句子嵌入表示模型(Sentence-BERT, SBERT)采用对比学习优化句子的表示,使向量空间更契合聚类需求,但主要关注全局相似性,难以区分类别边界的细微差异。基于简单对比学习的句子向量表示方法<sup>[7]</sup>利用数据增强提升短文本的区分度,但增强样本的质量对模型效果影响较大。生成式模型<sup>[8]</sup>可用于聚类任务,但计算成本较高,且缺乏明确的聚类优化目标。

针对这些不足,研究者们进一步引入任务特定信息来优化短文本聚类。领域自适应方法<sup>[9]</sup>可以提升预训练模型在特定场景的性能,但需大量领域数据进行微调,难以适应跨领域任务。持续的预训练<sup>[10]</sup>和少样本微调<sup>[11-12]</sup>能帮助模型学习细粒度语义,但依赖数据分布,对于数据量不足或类别不均衡时,性能可能受到影响。任务自适应语义扩展方法<sup>[13]</sup>是结合背景知识增强类别识别能力,但其效果取决于知识库的质量和覆盖范围,若知识库不完整或包含噪声,可能影响聚类效果。

针对上述问题,本文提出基于大语言模型(Large Language Model, LLM)的双通道特征融合短文本聚类方法(Dual-Channel Feature Fusion method for short text clustering based on large language models, DCFF),首先,建立语义增强伪标签学习模块:利用 LLM 生成关键词及权重,与原始文本融合增强语义密度,并通过自适应最优传输(Self-Adaptive Optimal Transport, SAOT)生成高置信度的伪标签,结合对比学习强化类内聚合与类间区分,确保全局语义一致性;其次,建立熵差异三元优化模块,筛选边界高信息量样本,再利用置信度加权损失和去噪机制优化局部结构,提高特征空间可

分性。最终,建立基于自注意力机制的全局与局部特征融合表示,生成兼具语义深度与结构精度的联合表示。

本文的主要贡献如下:

1) 提出基于大语言模型的双通道融合表示短文本聚类方法,通过建立全局语义增强与局部结构优化协同机制提升聚类的效果。

2) 提出了基于大语言模型的关键词权重融合方法,结合自适应最优传输的伪标签学习机制,提升文本表征在噪声环境下的语义判别能力。设计了基于熵差异的三元组采样与置信度加权损失,结合自注意力特征融合策略,缓解短文本局部敏感性与语义模糊性导致的表示偏移问题。

## 1 相关工作

### 1.1 基于信息增强的文本表示方法

由于短文本的字数有限和上下文缺失,使得语义推断更具有挑战,因此,研究者们提出多种信息增强短文本表示的方法。Petersen 等<sup>[14]</sup>通过小型文档库补充短文本的背景信息,但依赖知识库质量,覆盖不足或包含无关信息可能导致错误增强。Fang 等<sup>[15]</sup>提出的对比自监督学习方法通过数据增强构造正负样本,但若增强样本语义偏差较大,可能影响聚类准确性。Reimers 和 Gurevych<sup>[16]</sup>提出的 SBERT 采用预训练模型生成稠密向量,但主要优化全局相似性,难以精准区分细粒度语义。Zhang 等<sup>[17]</sup>结合异构性图神经网络进行多模态融合,但依赖高质量图结构,若标注错误或边稀疏,可能导致错误语义传播。Cai 等<sup>[18]</sup>采用注意力机制优化表示,并结合标签语义增强分类能力,但短文本信息有限,注意力分布易受个别词影响,导致不稳定性。尽管现有方法在增强短文本表示方面取得进展,但仍存在对外部知识依赖强、数据增强易引入噪声、难以捕捉细粒度语义、对图结构的质量敏感及注意力机制不稳定等问题,仍需探索更稳定高效的短文本表示方法,以提升聚类性能。

### 1.2 三元组采样优化

针对短文本聚类中语义边界模糊的问题,本文引入三元组学习机制,以提升嵌入表示的判别能力。每个三元组是由一个锚点样本(anchor)和两个候选样本(candidate1, candidate2)组成,形式为(a, c<sub>1</sub>, c<sub>2</sub>)。通过比较候选样本与锚点在嵌入空间中的相对距离,引导模型学习更有效的语义表示,从而更好地区分不同类别的文本。在训练过程中,三元组可以由大语言模型提供判别信号,以指示哪一个候选更接近锚点,从而构建基于监督信号的微调嵌入模型。在微调嵌入模型时,三元组样本对模型优化的贡献并不均等,采用随机采样既浪费计算资源,又难以提升类别边界的判别能力,其关键在于主动选择信息量丰富的三元组,优化类别边界模糊区域的嵌

入表示。现有研究从不同角度优化采样策略。Zhang 等<sup>[19]</sup>采用置信度采样,但未考虑全局语义分布,可能忽略整体结构。Conneau 等<sup>[20]</sup>通过语义难度感知采样优化表示学习,但依赖任务特定标注,不适用于无监督聚类。Cao 等<sup>[21]</sup>采用类别频率动态采样缓解长尾分布问题,但未考虑类内异质性,可能导致噪声样本过采样。Zhang 等<sup>[22]</sup>基于聚类熵选择高不确定性样本,但仅依赖熵值,未充分利用嵌入空间局部结构,可能遗漏关键边界样本。尽管这些方法各有优劣,但普遍存在全局建模不足、对噪声不够鲁棒、未充分利用局部结构等问题。因此,设计兼顾全局与局部信息、动态适应类别边界的采样策略,将有助于提升三元组学习效果,优化短文本聚类。

### 1.3 噪声抑制方法

在三元组预测过程中,大语言模型的不确定性可能导致部分样本带有噪声,影响嵌入模型的微调效果,甚至干扰模型的判别能力。因此,如何抑制噪声三元组的影响,提升嵌入模型的鲁棒性,是优化训练的重要问题。

早期研究<sup>[23-24]</sup>主要依赖文本预处理<sup>[25]</sup>去除停用词和特殊符号,但无法解决语义噪声,如标注错误或模糊表达。Rakib 等<sup>[26]</sup>通过异常值后处理优化聚类,但依赖初始分配,若初始聚类有误,可能导致错误归类。Zhang 等<sup>[27]</sup>采用对比损失增强实例区分,但未筛选噪声样本,可能引入异常梯度,影响模型稳定性。Kamthawee 等<sup>[28]</sup>提出互信息最大化方法,利用互信息增强鲁棒性,但计算复杂,且在高噪声环境下可能不

稳定,影响类别不均任务的表现。因此,降低噪声三元组对模型训练的影响仍是关键问题,未来研究可探索更精细的噪声检测与抑制策略,以确保模型从高质量样本中学习有效表示,同时减少异常样本的干扰。

## 2 DCFF 模型

为了丰富短文本的语义信息,增强类别区分能力,本文构建 DCFF。从全局视角出发,构建基于语义增强的伪标签对比学习模块,该模块首先利用 LLM 生成关键词短语和相应权重,将其与原始文本加权融合以捕获深层语义特征,增强全局语义密度;其次,基于 SAOT 与集群分配策略,将增强后的语义表示映射为高置信度伪标签。同时,为有效抑制噪声伪标签干扰,结合实例增强与对比学习机制即引入伪标签监督下的类内紧密度与类间可分性的双重约束,构建联合优化目标,最终通过端到端的训练获得判别性强、全局语义一致性高的文本向量表示。从局部视角,构建基于熵差异的三元表示优化模块,该模块基于熵和差异度联合的三元组采样策略,评估实例的不确定性,筛选高信息量的边界样本,利用置信度加权损失函数和去噪机制对嵌入模型进行局部精细化微调,抑制噪声干扰并增强局部判别性,生成对边界敏感的向量表示。最终,通过自注意力机制动态融合全局语义特征与局部判别特征,使全局特征保障主题连贯性,局部特征强化边界可分性,二者协同生成兼具语义深度与结构精度的联合表示以提升短文本聚类效果。DCFF 的模型如图 1。




图1 DCFF 模型图

Fig. 1 DCFF Model



## 2.1 基于语义增强的伪标签对比学习模块

由于短文本通常表达简略、主题的信息可能以隐式方式存在,导致全局语义稀疏,使得类间边界模糊、聚类判别性降低。为缓解这一问题,本文设计了一个基于语义增强的伪标签对比学习模块,其核心在于引入 LLM 生成的全局主题信息,辅助提升短文本的语义表示能力。具体而言,为弥补短文本语义覆盖范围不足的问题,本文构造结构化提示,引导 LLM 生成 3-5 个高质量、具有代表性的名词性关键词短语,用于揭示文本的潜在主题信息。这些关键词短语能够在语义空间中提供更加丰富和泛化的语义线索,从而补全原始短文本中缺失或隐晦的全局语义。

为了更有效地融合原始文本和增强特征的信息,本文进一步引入 LLM 评估两者在语义表达上的权重贡献。设原始文本的向量表示为  $\mathbf{t}$ , 关键词短语向量为  $\mathbf{k}$ , 则最终的语义增强表示为加权融合结果:

$$\mathbf{v} = \alpha \cdot \mathbf{t} + (1 - \alpha) \cdot \mathbf{k} \quad (1)$$

其中,融合系数  $\alpha \in [0, 1]$  表示原始语义和增强语义的相对重要性,取值由 LLM 基于语义完整性和上下文关联性评估得到。

该语义增强机制在伪标签生成和对比学习中联合使用,通过增强后的全局语义表示提升类间判别性,从而有效缓解短文本聚类中因语义稀疏带来的性能瓶颈。本模块首先利用 SBERT 对原始文本和关键词短语进行编码,并将两者加权融合,以生成语义增强的文本表示。其次,通过全连接层预测文本的类别概率分布  $P$ , 为后续的伪标签生成提供基础。为优化伪标签生成, SAOT 通过离散最优传输 (OT) 在样本分布与类分布之间建立映射关系,目标函数如下:

$$H = \min_{\pi, b} (\langle \pi, \mathbf{M} \rangle + \varepsilon_1 H(\pi) + \varepsilon_2 (\psi(b))^T) \quad (2)$$

$$s.t. \pi \mathbf{1} = \mathbf{a}, \pi^T \mathbf{1} = \mathbf{b}, \pi \geq 0, \mathbf{b}^T \mathbf{1} = 1$$

其中,  $\mathbf{M} = -\log P$  为代价矩阵,  $H(\pi) = \langle \pi, \log \pi - 1 \rangle$  是熵正则化<sup>[29]</sup>,  $\psi(b) = -\log b - \log(1 - b)$  作为惩罚函数,  $\pi$  是传输矩阵,  $\mathbf{a}$  和  $\mathbf{b}$  分别是样本和类的分布向量。

最后,最小化目标函数  $H$  得到的  $\pi$ , 再利用  $\arg\max$  得到伪标签  $\mathbf{Q}$ :

$$Q_{ij} = \begin{cases} 1, & \text{if } j = \arg \max_j \pi_{ij} \\ 0, & \text{otherwise} \end{cases} \quad (3)$$

为了提升模型对噪声的鲁棒性,学习高质量的文本表示,本模块利用伪标签与增强实例对进行对比学习,优化文本表示,使其在聚类中表现更优。具体地,通过上下文增强器<sup>[30]</sup>生成文本的增强对,并利用语义增强方式计算融合后的表示,同时利用聚类网络分别预测它们的聚类分配概率  $P^{(1)}$  和  $P^{(2)}$ ,

采用全连接层作为投影网络将表示映射到应用实例对比损失的空间,得到投影后的表示  $\mathbf{Z}^{(1)}, \mathbf{Z}^{(2)}$ 。

在对比学习阶段,来自同一原始文本的两个增强实例被视为正对,利用公式 (3) 得到伪标签  $\mathbf{Q}$  作为监督信号,其概率为  $P$ , 最小化交叉熵损失,使同类别的文本表示更聚集,其损失定义如下:

$$L_c = \frac{1}{N} \sum_{i=1}^N (-p_i \log P_i^{(1)} - p_i \log P_i^{(2)}) \quad (4)$$

实例级对比学习通过保持正样本对的投影表示之间的一致性,并最大化负样本对之间的距离。具体而言,在一个批次中,包含  $2N$  个增强文本及其对应的投影表示  $\mathbf{Z} = [\mathbf{Z}^{(1)}, \mathbf{Z}^{(2)}]^T$ , 对于每一对正样本  $(\mathbf{z}_i, \mathbf{z}_j)$ , 即来自同一原始文本的两个增强实例,其余  $2(N-1)$  个增强实例被视为负样本。正样本对  $(\mathbf{z}_i, \mathbf{z}_j)$  的损失函数定义如下:

$$l(\mathbf{z}_i, \mathbf{z}_j) = -\log \frac{\exp(\text{sim}(\mathbf{z}_i, \mathbf{z}_j)/\tau)}{\sum_{k=1}^{2N} \nu_{k \neq i} \exp(\text{sim}(\mathbf{z}_i, \mathbf{z}_k)/\tau)} \quad (5)$$

其中,  $\text{sim}(\mathbf{u}, \mathbf{v})$  表示向量  $\mathbf{u}$  和  $\mathbf{v}$  的余弦相似度,  $\tau$  表示温度参数,而  $\nu$  是一个指示函数。

实例级对比损失是在批次中的所有正样本对上计算的,包括  $(\mathbf{z}_i^{(1)}, \mathbf{z}_i^{(2)})$  和  $(\mathbf{z}_i^{(2)}, \mathbf{z}_i^{(1)})$  两种顺序的损失函数,利用公式 (5) 的损失函数,可以得到实例级对比损失如下:

$$L_i = \frac{1}{2N} \sum_{i=1}^N (l(\mathbf{z}_i^{(1)}, \mathbf{z}_i^{(2)}) + l(\mathbf{z}_i^{(2)}, \mathbf{z}_i^{(1)})) \quad (6)$$

通过将类别级对比学习和实例级对比学习的损失结合,最终的损失函数为:

$$L = L_c + \lambda L_i \quad (7)$$

其中,  $\lambda$  是平衡超参数。

在整个训练过程中,通过初始化伪标签、训练对比表示学习、周期性更新伪标签并更新聚类结果,模型的表示能力和聚类预测相互促进,逐步提高伪标签的质量,并优化最终的聚类效果。具体过程如下:

1) 初始化伪标签:首先,使用 K-means 对初始文本表示进行聚类,得到初始伪标签  $\mathbf{Q}$ 。

2) 训练鲁棒表示:以伪标签  $\mathbf{Q}$  作为监督信号进行训练,优化损失函数  $L$ 。

3) 周期性更新伪标签:使用对数分布(logarithmic schedule)<sup>[31]</sup>控制伪标签的更新频率,逐渐稳定模型。

4) 更新聚类结果:每轮训练后,通过  $P$  (聚类概率预测) 中的最大值确定最终聚类类别。

5) 判断是否终止训练:如果  $P$  两个连续更新之间的聚类分配变化小于阈值  $\delta$ , 或达到最大迭代次数,则终止训练。

为了清晰展示本模块的实现流程,算法 1 给出了基于语义增强的伪标签对比学习模块的伪代码。

**算法 1** 语义增强伪标签对比学习

输入: 数据集  $D$ , 类别数量  $n$ , 温度系数  $\tau$ , 最大迭代次数  $T$ ;

输出: 优化后的聚类模型  $M$ , 聚类结果  $C$ .

初始化:

- 1) 使用 SBERT 编码原始文本→基础表示  $E$ ;
- 2) 调用 LLM 生成关键词短语→语义增强特征  $K$ ;
- 3) 通过式(1)融合表示;
- 4) 运行 K-means 初始化聚类中心  $\mu$ ;
- 5) for epoch = 1 to T do:
- 6) 从  $D$  中采样批次数据  $X$ ;
- 7) 生成增强视图  $X_1, X_2 \leftarrow$  上下文增强器( $X$ );
- /\*伪标签生成阶段\*/
- 8) 计算代价矩阵  $M(X, \mu)$ ;
- 9) 通过式(2)求解传输矩阵  $\pi$ ;
- 10) 通过式(3)生成伪标签  $Q$ ;
- /\*对比学习阶段\*/
- 11)  $P_1 =$  聚类头(融合( $X_1, K_1$ ));
- 12)  $P_2 =$  聚类头(融合( $X_2, K_2$ ));
- 13) 通过式(4)计算类别对比损失  $L_C$ ;
- 14)  $Z_1 =$  投影头(融合( $X_1, K_1$ ));
- 15)  $Z_2 =$  投影头(融合( $X_2, K_2$ ));
- 16) 通过式(6)计算实例对比损失  $L_I$ ;
- 17) 通过式(7)更新模型参数;
- /\*动态更新机制\*/
- 18) if epoch 满足对数调度:
- 19) 更新聚类中心  $\mu \leftarrow$  Sinkhorn-KMeans(当前表示);
- 20) if  $\|\Delta\mu\| < \delta$ : break;
- 21) 返回最终聚类  $C \leftarrow \text{argmax}(\text{聚类概率})$

## 2.2 基于熵差异的三元表示优化模块

为了缓解短文本局部表示歧义性带来的特征空间结构松散及类间的边界模糊的问题, 本文提出一种针对性局部优化机制。该机制首先设计了基于类别分布熵与双模型预测差异度的三元组采样策略, 通过当前聚类结果提取局部区域中语义边界模糊、不确定性较高的样本。这些样本被作为“锚定句”选出, 能够最大程度地反映短文本的特征空间中的边界不清晰区域, 从而集中优化。其次, 通过引入 LLM, 对选出的三元组进行匹配判断, 并根据匹配结果估算置信度, 该置信度用于加权对比损失, 使得模型对高置信度样本更加关注, 从而有针对性地调整局部结构, 优化类间边界的清晰度。最后, 采用生成器与判别器的对抗训练机制, 进一步增强局部表示的判别能力。生成器生成潜在的负样本, 而判别器则负责判断这些负样本的质量。通过对抗训练, 优化过程能够去除局部噪声、强化边界明确性, 进而促进模型对关键样本的学习, 增强局部表示的判别能力。

### 2.2.1 基于熵和差异度的三元组采样方法

为了动态筛选模糊实例作为锚定样本, 用嵌入模型  $f$  将数据  $\{x_1 \dots x_N\}$  转为嵌入向量  $Z = \{z_1 \dots z_N\}$ , 并对  $Z$  进行聚类, 得到  $K$  个初始簇, 计算每个样本对聚类中心  $\mu_k$  的软分配概率<sup>[32]</sup>:

$$p_{ik} = \frac{(1 + \|z_i - \mu_k\|^2 / \alpha)^{-\frac{\alpha+1}{2}}}{\sum_k (1 + \|z_i - \mu_k\|^2 / \alpha)^{-\frac{\alpha+1}{2}}} \quad (8)$$

其中,  $\mu_k$  为第  $k$  个聚类中心,  $\alpha = 1$  是自由度。

利用公式(8)选取概率最高的  $K_{\text{closest}}$  个近邻聚类, 计算样本熵, 用于衡量其簇归属的不确定性 ( $p'_{ik}$  为归一化概率)。

$$h_i = - \sum_{k=1}^{K_{\text{closest}}} p'_{ik} \log(p'_{ik}) \quad (9)$$

进一步, 根据聚类中心总数  $K$  自适应确定  $K_{\text{closest}}$  如下:

$$K_{\text{closest}} = \max(\varepsilon K, 2) \quad (10)$$

其中,  $\varepsilon$  是一个常数, 用于确保在聚类中心数量较多时选取足够的近邻以获得稳定的熵估计。

锚定样本仅依靠熵值无法全面反映不确定性, 因此, 通过输入扰动, 构建两个独立嵌入表示模型  $f_1$  和  $f_2$ , 其中,  $f_2$  的输入数据添加了高斯噪声 ( $\sigma=0.01$ ), 然后利用公式(8)获得的概率, 计算两者在近邻聚类上的概率差异:

$$D_i = \frac{1}{K_{\text{closest}}} \sum_{k=1}^{K_{\text{closest}}} |p_{ik}^1 - p_{ik}^2| \quad (11)$$

其中  $D_i$  越大, 表示两个模型对样本  $i$  的簇分配越不确定。

将公式(9)的熵值  $h_i$  和公式(11)的差异度  $D_i$  结合, 计算综合的不确定性:

$$U_i = h_i + \lambda \cdot D_i \quad (12)$$

其中,  $\lambda$  是权重超参数, 用于平衡熵和差异度的贡献。

按照  $U_i$  降序排列整个数据集, 并设置两个阈值  $\gamma_{\text{high}}$  和  $\gamma_{\text{low}}$  用来仅筛选不确定性高的实例作为锚定样本, 构建高信息量三元组。选定锚定句后, 从其最近的  $K_{\text{closest}}$  个聚类中随机采样两个不同的聚类  $C_1$  和  $C_2$ , 分别选取样本  $s_1$  和  $s_2$  作为候选样本。这些候选句是锚定句的正例或硬负例。为避免冗余, 所有三元组经去重筛选。继续采样三元组, 直到达到预定数量  $N$ 。

### 2.2.2 基于置信度感知对抗去噪方法微调嵌入器

通过上述采样方法获取三元组后, 再利用 LLM 进行预测, 但在无监督环境下, LLM 可能难以区分细粒度语义差异, 导致错误匹配, 引入噪声并扰乱嵌入空间结构。为此, 本文结合置信度加权损失与对抗去噪方法构造噪声优化的可靠性增强机制(Noise-Optimized Reliability-Enhanced Mechanism, NOREM)优化嵌入表示。如图 2 所示。




图2 噪声优化的可靠性增强机制

Fig. 2 Noise-Optimized Reliability-Enhanced Mechanism

本文利用选择结果的置信度作为权重，动态调整损失函数中对各三元组的关注程度。对于锚定句  $a$  及其候选句  $c_1$  和  $c_2$ ，利用 LLM 选择匹配的正样本  $c_1$ ，随后通过嵌入模型计算三者间的语义相似度。为了量化 LLM 选择的可信度，设计基于 Sigmoid 函数的置信度估计公式：

$$Conf = \text{Sigmoid}\left(\frac{\text{sim}(a, c_1)}{\text{sim}(a, c_1) + \text{sim}(a, c_2)} \cdot T\right) \quad (13)$$

其中，温度系数  $T$  控制相似度分布的尖锐程度。置信度越高，表明当前三元组的语义判别性越强。

进一步，将置信度作为权重融入对比损失函数。针对每个三元组，计算锚点样本与正负样本的相似度得分，并利用实例损失<sup>[33-34]</sup>使得正负样本分离：

$$loss_{\text{instance}} = -\log\left(\frac{\exp(score_{\text{pos}})}{\exp(score_{\text{pos}}) + \sum \exp(score_{\text{neg}})}\right) \quad (14)$$

$$score_{\text{pos}} = \text{sim}(a, c_1) / T \quad (15)$$

$$score_{\text{neg}} = \text{sim}(a, c_2) / T \quad (16)$$

利用公式(18)通过置信度加权，模型能够聚焦于高可信度样本的优化，同时引入对称损失约束以增强表示一致性。归一化后的主体损失  $loss_{\text{main}}$  综合所有样本的加权损失，形成初步优化目标：

$$loss_{\text{main}} = \frac{1}{\text{num}} \left( \sum_{i=1}^{\text{num}} loss_{\text{conf}} + \sum_{i=1}^{\text{num}} \text{sym}loss_{\text{conf}} \right) \quad (17)$$

$$loss_{\text{conf}} = Conf[i] \times loss_{\text{conf}} \quad (18)$$

为了减少噪声数据对模型的影响，并优化负样本质量，采用对抗式去噪策略。该策略通过判别器和生成器的对抗训练机制，去除噪声并生成更高质量的负样本，提升嵌入模型的表达能力。本文判别器采用双层神经网络结构，接收嵌入向量通过非线性变换与概率映射，输出样本属于真实正样本的置信度评分：

$$D(x) = \sigma(W_2 \cdot \text{ReLU}(W_1 \cdot x + b_1) + b_2) \quad (19)$$

其中， $x$  是输入的嵌入向量，ReLU 是激活函数， $\sigma$  是 Sigmoid 函数，用来将输出映射到 0 到 1 之间，表示样本属于真实正样本的概率。生成器则通过噪声映射生成伪造负样本，其定义为：

$$G(z) = \tanh(W_2 \cdot \text{ReLU}(W_1 \cdot z + b_1) + b_2) \quad (20)$$

其中，输入随机噪声  $z \sim N(0,1)$ ，利用隐层非线性激活与缩放后，输出伪造嵌入向量，旨在模拟真实数据的分布特征。

在对抗训练中，判别器与生成器交替优化。判别器的目标是区分真实样本与生成样本：对真实正样本判别器预测结果  $D(\text{emb}_{\text{pos}})$  被约束逼近 1；对生成器产生的伪造样本  $G(z)$ ，判别器预测结果  $D(G(z))$  则被压制至 0。利用  $D(\text{emb}_{\text{pos}})$  和  $D(G(z))$  构造损失函数如下：

$$loss_{\text{disc}} = \frac{1}{2} [-\log D(\text{emb}_{\text{pos}}) - \log(1 - D(G(z)))] \quad (21)$$

生成器的目标是欺骗判别器：生成器的优化目标是使其生成的伪造样本  $G(z)$  尽可能被判别器误判为真实正样本。为此，构建生成器的损失函数，该损失旨在驱使判别器对生成样本  $G(z)$  的预测值  $D(G(z))$  接近 1。

$$loss_{\text{gen}} = -\log D(G(z)) \quad (22)$$

最终，模型通过联合损失函数整合对比学习与对抗训练目标：

$$loss_{\text{total}} = loss_{\text{main}} + \lambda_1 \cdot loss_{\text{disc}} + \lambda_2 \cdot loss_{\text{gen}} \quad (23)$$

其中，超参数  $\lambda_1$  和  $\lambda_2$  调控对抗训练对整体优化的贡献权重。

整个训练过程中，首先进行初始聚类，随后采样三元组，并基于 LLM 进行匹配预测。接着，利用置信度加权损失优化嵌入模型，同时通过对抗式去噪提升模型的抗噪能力。不断重复上述步骤，逐步优化嵌入模型  $f$ 。

为了清晰展示本模块的实现流程，算法 2 给出了基于熵差异的三元表示优化模块的伪代码。

#### 算法 2. 熵差异三元表示优化

输入：嵌入模型  $f$ ，数据集  $D$ ，类别数  $K$ ，对抗系数  $\lambda$ ，训练次数  $N$ ；

输出：优化后的嵌入模型  $f'$ 。

初始化：

- 1) 初始化嵌入模型  $f$ ;
- 2) 计算聚类中心  $\mu \leftarrow \text{K-means}(f(D), K)$ ;
- 3) for epoch in  $N$  do:  
/\*动态三元组采样\*/
- 4) 通过式(8)计算软分配  $P$ ;
- 5) 通过式(9)计算熵  $H$ ;
- 6) 独立初始化嵌入模型  $f_1, f_2$ ，通过式(10)计算差异



度  $D$ ;

- 7) 依据式(11)选择锚点样本  $a$ ;
- /\*置信度感知优化\*/
- 8) 采样三元组  $T$  并通过 LLM 进行预测  $\leftarrow (a, c_1, c_2)$ ;
- 9) 通过式(12)计算置信度  $\omega$ ;
- 10) 通过式(14)计算主体损失  $loss_{main}$ ;
- /\*对抗去噪训练\*/
- 11) 初始化判别器  $D(x)$  和生成器  $G(z)$ ;
- 12) 最小化式(17)更新判别器  $D(x)$ ;
- 13) 最小化式(18)更新判别器  $G(z)$ ;
- 14) 通过最小化整体损失  $loss_{total}$  联合更新  $f$ ;
- 15) 返回优化后的嵌入模型  $f'$ ;

### 2.2.3 多头自注意力机制融合模块

在语义增强伪标签学习模块中, LLM 通过全局语义增强与对比约束优化向量表示, 以捕获深层主题一致性, 但易受局部噪声影响。熵差异的三元优化模块则基于关键样本微调, 提升表示的结构判别性, 提高几何可分性, 但全局泛化能力有限。为了兼顾全局语义深度与局部结构精度, 本文提出基于多头自注意力的动态融合策略, 利用语义增强伪标签学习模块获取嵌入表示  $E_1$ , 熵差异的三元优化模块获取嵌入表示  $E_2$ , 通过线性变换生成查询( $Q$ )、键( $K$ )、值( $V$ ):

$$Q = E_1 \cdot W_Q \quad (24)$$

$$K = E_2 \cdot W_K \quad (25)$$

$$V = E_2 \cdot W_V \quad (26)$$

利用公式(24)和(25)得到的查询和键, 计算注意力得分, 并使用 softmax 得到注意力权重  $A_{weights}$ :

$$A_{scores} = \frac{Q \cdot K^T}{\sqrt{d_{head}}} \quad (27)$$

$$A_{weights} = \text{softmax}(A_{scores}) \quad (28)$$

为了使嵌入表示  $E_1$  充分融合嵌入表示  $E_2$  的信息, 最终设计了兼具判别性和结构性的表示, 并使用注意力权重值对  $V$  进行加权求和:

$$A_{output} = A_{weights} \cdot V \quad (29)$$

将所有头的输出拼接, 最终通过线性变换得到融合后的向量表示  $F$ , 采用 K-means 算法对  $F$  进行聚类, 获得最终的聚类结果。

$$F = \text{concat}(A_{output_1}, \dots, A_{output_g}) \cdot W_{out} \quad (30)$$

## 3 实验与结果分析

### 3.1 实验数据集

本文在 8 个真实世界数据集上进行了广泛实验。Tweet

数据集<sup>[35]</sup>包含 2472 条推文, 涉及 89 个查询, 来自 2011-2012 年 TREC 微博话题追踪数据。AgNews 是 AG 新闻语料库的子集, 包含 8000 条新闻标题, 分为 4 个主题。StackOverflow 数据集包含 20000 个问题标题, 对应 20 个标签。Biomedical 数据集由 20000 篇论文标题组成, 涵盖 20 个主题。SearchSnippets 数据集<sup>[36]</sup>包含 12340 个搜索摘要, 分属 8 个类别。GoogleNews 数据集由 11109 篇新闻标题和摘要组成, 涵盖 152 个事件, 进一步分为 Google-News-TS (标题+摘要)、GoogleNews-T (仅标题) 和 GoogleNews-S (仅摘要)。

### 3.2 相关参数设置

本文采用的实验平台基于 Ubuntu 20.04.6 LTS 操作系统, 内核版本为 5.15.0-127-generic, 硬件配置包括 AMD EPYC 7313 16-Core 处理器, 4 块 NVIDIA GeForce RTX 4090 显卡 (每块显存为 24 GB), 开发语言为 Python。本文使用 PyTorch 构建模型, 并采用 Adam 优化器进行训练。实验超参数设置如下: 式(12)中的权重超参数  $\lambda$  经过多次训练调试设置为 1, 式(23)中的权重超参数  $\lambda_1$  和  $\lambda_2$  经过多次训练调试分别设置为 0.5 和 0.3, 关于三元组采样, 本文设置  $\gamma_{high}=0$ ,  $\gamma_{low}=20\%$  和  $Q=1024$ , 关于嵌入器, 在第 2.1 节中的基于语义增强的伪标签对比学习模块中, 本文选择 distilbert-base-nli-stsb-mean-tokens 对文本进行编码, 在第 2.2 节中个基于熵差异的三元表示优化模块中, 本文专注于最先进的预训练嵌入器 Instructor。

### 3.3 评价指标

在文本聚类时, 使用的两种评估指标, 即准确率(ACC)和归一化互信息(NMI)。

准确率的定义为:

$$ACC = \frac{\sum_{i=1}^N \mathbf{1}(y_i = \text{map}(\hat{y}_i))}{N} \quad (31)$$

其中,  $y_i$  和  $\hat{y}_i$  分别是给定文本  $x_i$  的真实标签和预测标签, Map( $\cdot$ )是通过匈牙利算法<sup>[37]</sup>将每个预测标签映射到相应的目标标签。

归一化互信息定义为:

$$NMI = (Y, \hat{Y}) = \frac{I(Y, \hat{Y})}{\sqrt{H(Y)H(\hat{Y})}} \quad (32)$$

其中,  $Y$  和  $\hat{Y}$  分别是真实标签和预测标签,  $I(\cdot)$  是互信息,  $H(\cdot)$  是熵。

### 3.4 对比实验结果与分析

为了验证 DCFF 的有效性, 将 DCFF 的性能与最先进的相關方法进行比较, 包括 K-means\_IC(2020)、SCCL(2021)、



CLUSTERLLM(2023)、RSTC(2023)<sup>[38]</sup>、STSPL-SSC(2024)<sup>[39]</sup>、MIST(2024)。结果如表 1 所示。

表1 对比实验结果

Tab. 1 Comparative experimental results

|                       | Tweet         |              | Agnews       |              | Biomedical   |              | SearchSnippets |              |
|-----------------------|---------------|--------------|--------------|--------------|--------------|--------------|----------------|--------------|
|                       | ACC           | NMI          | ACC          | NMI          | ACC          | NMI          | ACC            | NMI          |
| K-means_IC            | 66.54         | 84.84        | 66.30        | 42.03        | 40.44        | 32.16        | 63.84          | 42.03        |
| SCCL                  | 73.10         | 86.66        | 83.10        | 61.96        | 42.49        | 39.16        | 79.90          | 63.78        |
| CLUSTERLLM            | 68.18         | 87.29        | 83.53        | 59.54        | 46.37        | 37.45        | 78.36          | 65.18        |
| RSTC                  | 75.20         | 87.35        | 84.24        | 62.45        | 48.40        | 40.12        | 80.10          | 69.74        |
| STSPL-SSC             | 79.59         | 88.02        | 89.92        | <b>71.66</b> | 47.43        | 42.49        | 81.04          | 65.46        |
| MIST                  | 91.75         | 95.12        | 89.47        | 70.25        | 39.15        | 34.66        | 76.72          | 67.69        |
| <b>DCFF</b>           | <b>92.83</b>  | <b>95.78</b> | <b>91.61</b> | 71.43        | <b>49.32</b> | <b>44.83</b> | <b>83.60</b>   | <b>73.20</b> |
| <b>Improvement(↑)</b> | <b>1.08</b>   | <b>0.66</b>  | <b>1.69</b>  | -0.23        | <b>0.92</b>  | <b>2.34</b>  | <b>2.56</b>    | <b>3.46</b>  |
|                       | GoogleNews-TS |              | GoogleNews-T |              | GoogleNews-S |              | Stackoverflow  |              |
|                       | ACC           | NMI          | ACC          | NMI          | ACC          | NMI          | ACC            | NMI          |
| K-means_IC            | 79.81         | 92.91        | 68.88        | 83.55        | 74.48        | 88.53        | 74.96          | 70.27        |
| SCCL                  | 82.51         | 93.01        | 69.01        | 85.10        | 73.44        | 87.98        | 70.83          | 69.21        |
| CLUSTERLLM            | 74.88         | 92.41        | 69.94        | 87.04        | 71.54        | 89.50        | 85.72          | 81.58        |
| RSTC                  | 83.27         | 93.15        | 72.27        | 87.39        | 79.32        | 89.40        | 83.30          | 74.11        |
| STSPL-SSC             | 84.41         | 94.32        | 81.01        | 91.11        | 82.30        | 91.18        | 86.74          | <b>82.54</b> |
| MIST                  | 90.63         | 96.42        | 78.80        | 89.31        | 82.14        | 90.86        | 79.65          | 78.59        |
| <b>DCFF</b>           | <b>91.75</b>  | <b>96.88</b> | <b>84.20</b> | <b>93.15</b> | <b>84.47</b> | <b>91.72</b> | <b>87.80</b>   | 81.46        |
| <b>Improvement(↑)</b> | <b>1.12</b>   | <b>0.46</b>  | <b>3.19</b>  | <b>2.04</b>  | <b>2.17</b>  | <b>0.54</b>  | <b>1.06</b>    | -1.08        |

由表 1 的结果中可以发现：

1) DCFF 通过引入 LLM 语义增强与伪标签和对比学习机制，提升了初始语义密度和伪标签质量，从而为后续聚类提供了更为稳定的起点，避免了 K-means\_IC 方法中由于初始聚类质量差而导致的优化问题。

2) 与 SCCL 方法相比，DCFF 不仅具有实例级对比损失以缓解噪声影响，还通过引入语义增强提升了伪监督信号的质量，增强了全局目标的稳定性，避免了 SCCL 目标容易退化的情况。

3) DCFF 比 CLUSTERLLM 相比更具鲁棒性，它通过置信度加权和对抗去噪机制控制 LLM 的输出可信度，并抑制噪声，从而实现更稳健的局部结构优化，避免了 CLUSTERLLM 由于个别判断错误导致的训练信号不稳定。

4) DCFF 引入了边界感知的三元组优化机制，强化了类别边界的区分能力，从而解决了 RSTC 在处理类别边界时的模糊性问题。

5) 相比于 STSPL-SSC，DCFF 通过语义增强提升了表示的表达力，并引入自适应传输生成高置信度伪标签，结合对比约束提升了监督信号的鲁棒性，有效抑制了伪标签误导的问题。

6) DCFF 通过 LLM 生成关键词短语，提升了表示的语义

丰富性，并融合了局部结构信息，弥补了 MIST 方法在稠密表示学习中未能充分捕捉稀疏而关键语义关系的不足。

7) DCFF 通过关键词与原始文本的动态融合增强全局语义，结合熵差异采样优化局部边界，并利用多头注意力机制融合全局与局部特征，在短文本聚类任务上展现了更好的效果。

3.5 消融实验

为了考察 DCFF 的每个模块对最终性能的影响，本文进行消融实验。

-SE 表示在 DCFF 模型的基础上，仅去除语义增强这一步骤。

-Difference 表示在三元组采样时，仅基于熵而不再考虑差异度。

-Confidence 表明去掉对样本置信度的加权操作，模型将不再根据置信度动态调整损失函数中的各三元组的关注程度。

-AdvDenoise 表明去掉生成器和判别器的对抗式去噪方法。

具体消融实验结果如表 2 所示。

表2 消融实验结果

Tab. 2 Ablation experimental results

|             | Tweet         |              | Agnews       |              | Biomedical   |              | SearchSnippets |              |
|-------------|---------------|--------------|--------------|--------------|--------------|--------------|----------------|--------------|
|             | ACC           | NMI          | ACC          | NMI          | ACC          | NMI          | ACC            | NMI          |
| <b>DCFF</b> | <b>92.83</b>  | <b>95.78</b> | <b>91.61</b> | <b>71.43</b> | <b>49.32</b> | <b>44.83</b> | <b>83.60</b>   | <b>73.20</b> |
| -SE         | 91.71         | 95.20        | 90.88        | 70.28        | 48.05        | 43.91        | 81.82          | 72.37        |
| -Difference | 91.42         | 94.72        | 90.56        | 70.83        | 47.47        | 44.34        | 82.83          | 72.85        |
| -Confidence | 91.96         | 94.55        | 90.61        | 69.80        | 48.61        | 44.00        | 83.35          | 71.79        |
| -AdvDenoise | 92.52         | 95.11        | 91.12        | 70.45        | 49.10        | 43.66        | 82.48          | 72.49        |
|             | GoogleNews-TS |              | GoogleNews-T |              | GoogleNews-S |              | Stackoverflow  |              |
|             | ACC           | NMI          | ACC          | NMI          | ACC          | NMI          | ACC            | NMI          |
| <b>DCFF</b> | <b>91.75</b>  | <b>96.88</b> | <b>84.20</b> | <b>93.15</b> | <b>84.47</b> | <b>91.72</b> | <b>87.80</b>   | <b>81.46</b> |
| -SE         | 90.92         | 95.67        | 82.25        | 92.28        | 83.80        | 90.58        | 86.76          | 81.04        |
| -Difference | 91.28         | 95.89        | 82.65        | 92.33        | 83.51        | 90.73        | 87.13          | 80.67        |
| -Confidence | 90.63         | 96.43        | 83.46        | 92.81        | 82.85        | 90.45        | 86.55          | 80.65        |
| -AdvDenoise | 90.47         | 95.96        | 82.59        | 92.54        | 83.60        | 90.37        | 86.41          | 80.69        |

由表 2 的结果中可以发现:

1) 去掉语义增强模块后, 由于缺乏通过关键词引导的深层语义建模, 使得原始文本表示在捕捉细粒度语义信息上存在不足, 无法有效弥补语义空缺。尤其在处理长尾类别时, 由于这些类别的样本较少且特征不够突出, 导致类间的语义重叠更加严重。

2) 去掉差异度信息后, 三元组采样仅依赖熵值来判断样本的不确定性, 难以有效区分那些具有明显预测分歧的样本。这使得模型在选择具有高信息量的样本时, 无法充分覆盖局部边界模糊区域, 导致对这些区域的优化不足。

3) 去掉置信度加权损失后, 三元组标签的可信度无法有效衡量, 导致错误预测与高置信度样本的匹配权重相同, 无法抑制噪声样本的影响。这种情况可能放大噪声样本在训练过程中的干扰。

4) 去掉对抗式去噪模块后, 缺乏生成器区分噪声的机制, 负样本的质量主要依赖于随机抽取, 这使得边界学习的精确度降低, 影响模型在微调阶段的表现, 导致微调效果未能达到最佳状态。

### 3.6 不同嵌入表示融合方法对 DCFF 性能的影响

为了探索和比较不同嵌入表示的融合方法在提升聚类性能和嵌入表示稳定性方面的表现, 本文分别采用了相加、拼接、最大池化和多头自注意力机制进行实验。通过此实验确定最适合在 DCFF 模型中使用的融合方法。为了更直观地进行对比, 本文计算了不同方法下八个数据集的 ACC 和 NMI 的平均值。实验结果如表 3 所示。

由表 3 中的结果可以发现:

1) 相加方法对全局与局部表示采用统一处理方式, 未能

区分其在语义表达中的差异性, 导致关键信息被稀释, 影响边界判别能力。

2) 拼接方法虽保留两类特征, 但缺乏有效的跨维建模机制, 无法充分捕捉全局与局部之间的语义交互, 融合效果有限, 难以提升语义一致性与边界清晰度。

3) 最大池化方法在融合过程中仅保留显著激活值, 忽略潜在的细粒度语义差异, 造成在边界样本上的聚类稳定性下降。

4) 自注意力机制通过关注输入向量之间的关系, 能够有效捕捉嵌入向量中重要的信息部分, 提升信息融合的效果。基于实验结果, 本文选择了多头自注意力机制来进行向量融合, 以更好地捕捉特征之间的关系, 增强聚类性能。

表3 不同融合方法的实验结果比较

Tab. 3 Comparison of fusion methods' results

| 融合方法                      | ACC          | NMI          |
|---------------------------|--------------|--------------|
| Add                       | 81.71        | 79.79        |
| Cat                       | 81.84        | 80.11        |
| Max_Pooling               | 82.37        | 79.94        |
| Multi-Head_Self-Attention | <b>83.19</b> | <b>81.05</b> |

### 3.7 注意力头数对 DCFF 性能的影响

为了验证多头自注意力机制融合模块中注意力头数对 DCFF 性能的影响, 通过此实验确定最适合在 DCFF 模型中的注意力头数。为了更直观地进行对比, 本文计算了不同方法下八个数据集的 ACC 和 NMI 的平均值。实验结果如表 4 所示。

由表 4 中的实验结果可以看出, 当注意力头数为 8 时, DCFF 性能达到最好。当头数为 16 时, 模型性能急剧下降,

说明注意力头数并不是越多越好,而是当模型的性能达到较好的效果后,增加头数反而会降低模型的性能。

表4 不同注意力头数的实验结果比较

Tab. 4 Comparison of results with varying attention

| heads |              |              |
|-------|--------------|--------------|
| 头数    | ACC          | NMI          |
| 2     | 80.78        | 79.68        |
| 4     | 82.24        | 80.21        |
| 8     | <b>83.19</b> | <b>81.05</b> |
| 16    | 81.46        | 79.13        |
| 32    | 82.71        | 80.80        |

### 3.8 关键超参数对 DCFF 性能的影响

为了验证各关键超参数对模型性能的影响,本文设计了参数敏感性实验,分别考察了式(11)中的权重超参数 $\lambda$ ,式(19)中的权重超参数 $\lambda_1$ 和 $\lambda_2$ 在不同取值下对模型性能的影响。为便于对比,统计了各参数配置在8个数据集上的ACC和NMI




图3 单参数粗搜索分析

Fig. 3 Single-Parameter Preliminary Search

2) 网格精搜索: 如表 6, 在  $\lambda_1 \in [0.4, 0.5, 0.6]$  和  $\lambda_2 \in [0.2, 0.3, 0.4]$  范围内测试所有组合。

根据表 6 中 DCFF 性能达到最优时的实验结果, 选择最优组合为  $\lambda_1=0.5+\lambda_2=0.3$ 。

表6 网格搜索实验结果(ACC/NMI)

Tab. 6 Grid Search Experimental Results(ACC/NMI)

| $\lambda_1/\lambda_2$ | 0.2           | 0.3                  | 0.4           |
|-----------------------|---------------|----------------------|---------------|
| 0.4                   | 82.50 / 80.20 | 82.90 / 80.60        | 82.30 / 79.90 |
| 0.5                   | 82.80 / 80.50 | <b>83.19 / 81.05</b> | 82.70 / 80.30 |
| 0.6                   | 82.20 / 79.80 | 82.60 / 80.20        | 81.90 / 79.50 |

## 4 结语

本文针对短文本聚类中语义稀疏性、噪声干扰及边界模糊性等挑战, 提出了一种基于双模块协同优化的深度聚类方法 DCFF。通过大语言模型(LLM)驱动的全局语义增强与伪标签对比学习模块, 有效扩充短文本的语义密度并抑制噪声干扰; 结合基于熵差异的三元表示优化模块, 聚焦关键样本的

平均值。实验结果如下表所示, 进一步验证了各参数设置的合理性, 并为实际应用中的参数选择提供参考。

关于式(12)中的权重超参数 $\lambda$ 的实验结果如表 5 所示。

通过实验结果发现, 当 $\lambda$ 为 1.0 时, DCFF 性能达到最好。

表5 超参数 $\lambda$ 对模型性能的影响

Tab. 5 Hyperparameter  $\lambda$  Sensitivity Analysis

| $\lambda$ 取值 | ACC          | NMI          |
|--------------|--------------|--------------|
| 0.0          | 82.10        | 80.29        |
| 0.5          | 81.20        | 79.30        |
| 1.0          | <b>83.19</b> | <b>81.05</b> |
| 1.5          | 81.60        | 79.50        |
| 2.0          | 79.90        | 77.20        |

式(23)中的权重 $\lambda_1$ 和 $\lambda_2$ 分别控制判别器损失和生成器损失的贡献强度。为确定最优权重组合, 本文采用分阶段策略:

1) 单参数粗搜索: 固定 $\lambda_2=0$ 扫描 $\lambda_1$ , 固定 $\lambda_1=0$ 扫描 $\lambda_2$ ,  $\lambda_1$ 在 0.5 附近达到单参数最优,  $\lambda_2$ 在 0.3 附近达到单参数最优。如图 3 所示。

局部结构优化, 提升特征空间的判别性; 最终通过多头自注意力机制融合全局与局部特征, 实现语义深度与几何可分性的动态平衡。实验结果表明, DCFF 在多个数据集与任务场景下均表现出显著的有效性。消融分析进一步验证了各模块的协同必要性。未来工作将探索跨模态短文本的联合表示优化, 并设计轻量化部署方案以适配实时性需求。

## 参考文献

- [1] LIU W, SU J, CHEN C, et al. Leveraging distribution alignment via stein path for cross-domain cold-start recommendation[C]// Proceedings of the 35th International Conference on Neural Information Processing Systems. Red Hook, NY: Curran Associates, Inc., 2021: 19223-19234.
- [2] STIEGLITZ S, MIRBABAIE M, ROSS B, et al. Social media analytics challenges in topic discovery, data collection, and data preparation [J]. International Journal of Information Management, 2018, 39: 156-168.
- [3] LI, SHAO H, SUN D, et al. Unsupervised belief representation learning with information-theoretic variational graph auto-encoders[C]// Proceedings of the 45th International ACM SIGIR Conference on Research and Development in Information Retrieval. New York: ACM, 2022: 1728-1738.

- [4] DEVLIN J, CHANG M W, LEE K, et al. Bert: Pre-training of deep bidirectional transformers for language understanding[C]// Proceedings of the 2019 conference of the North American chapter of the Association for Computational Linguistics: Human Language Technologies. Stroudsburg: ACL, 2019: 4171-4186.
- [5] LIU Z, LIN W, SHI Y, et al. A Robustly optimized BERT pre-training approach with post-training[C]// Proceedings of the 20th Chinese National Conference on Computational Linguistics. Huhhot: Chinese Information Processing Society of China, 2021: 1218-1227.
- [6] RAFFEL C, SHAZEER N, ROBERTS A, et al. Exploring the limits of transfer learning with a unified text-to-text transformer[J]. Journal of Machine Learning Research, 2020, 21(140): 1-67.
- [7] GAO T, YAO X, CHEN D. SimCSE: Simple contrastive learning of sentence embeddings [C]// Proceedings of the 2021 Conference on Empirical Methods in Natural Language Processing. Stroudsburg: ACL, 2021: 6894-6910.
- [8] RADFORD A, NARASIMHAN K, SALIMANS T et al. Improving language understanding by generative pre-training[C]// Proceedings of the North American Chapter of the Association for Computational Linguistics. Stroudsburg: ACL, 2018: 67-73.
- [9] BEN-DAVID S, BLITZER J, CRAMMER K, et al. A theory of learning from different domains[J]. Machine Learning, 2010, 79: 151-175.
- [10] GURURAJAN S, MARASOVIĆ A, SWAYAMDIP S, et al. Don't stop pretraining: adapt language models to domains and tasks[C]// Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics. Stroudsburg: ACL, 2020: 8342-8360.
- [11] SCHICK T, SCHÜTZE H. Exploiting Cloze-questions for few-shot text classification and natural language inference[C]// Proceedings of the 16th Conference of the European Chapter of the Association for Computational Linguistics. Stroudsburg: ACL, 2021: 255-269.
- [12] LESTER B, AL-RFOU R, CONSTANT N. The power of scale for parameter-efficient prompt tuning[C]// Proceedings of the 2021 Conference on Empirical Methods in Natural Language Processing. Stroudsburg: ACL, 2021: 3045-3059.
- [13] DU L, DING X, LIU T, et al. Learning event graph knowledge for abductive reasoning[C]// Proceedings of the 59th Annual Meeting of the Association for Computational Linguistics and the 11th International Joint Conference on Natural Language Processing. Stroudsburg: ACL, 2021: 5181-5190.
- [14] HENRY P, JOSIAH P. Enhancing short text clustering with small external repositories[C]// Proceedings of the Ninth Australasian Data Mining Conference. Ballarat: Australian Computer Society, 2011:79-90.
- [15] FANG H, XIE P. An End-to-End contrastive self-supervised learning framework for language understanding [J]. Transactions of the Association for Computational Linguistics, 2022, 10: 1324-1340.
- [16] REIMERS N, GUREVYCH I. Sentence-BERT: sentence embeddings using siamese bert-networks[C]// Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th Int Joint Conf on Natural Language Processing. Stroudsburg: ACL, 2019: 3982-3992.
- [17] ZHANG B, HE Q, ZHANG D. Leverage Heterogeneous Graph Neural Networks for Short-Text Conceptualization [C]// Proceedings of the 11th Chinese National Conference on Social Media Processing (SMP 2023). Cham: Springer, 2023: 90-103.
- [18] CAI L, SONG Y, LIU T, et al. A Hybrid bert model that incorporates label semantics via adjustive attention for multi-label text classification[J]. IEEE Access, 2020, 8: 152183-152192.
- [19] ZHANG X, ZHAO J, LECUN Y. Character-level convolutional networks for text classification[C]// Proceedings of the 29th International Conference on Neural Information Processing Systems. Red Hook, NY: Curran Associates, Inc., 2015: 649 - 657.
- [20] CONNEAU A, KIELA D, SCHWENK H, et al. Supervised learning of universal sentence representations from natural language inference data[C]// Proceedings of the 2017 Conference on Empirical Methods in Natural Language Processing. Stroudsburg: ACL, 2017: 670-680.
- [21] CAO K, WEI C, GAIDON A, et al. Learning imbalanced datasets with label-distribution-aware margin loss[C]// Proceedings of the 33rd International Conference on Neural Information Processing Systems. Red Hook, NY: Curran Associates, Inc., 2019:1567 - 1578.
- [22] ZHANG Y, WANG Z, SHANG J. ClusterLLM: large language models as a guide for text clustering[C]// Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing. Stroudsburg: ACL, 2023: 13903-13920.
- [23] XU J, XU B, WANG P, et al. Self-taught convolutional neural networks for short text clustering[J]. Neural Networks, 2017, 88: 22-31.
- [24] HADIFAR A, STERCKX L, DEMEESTER T, et al. A self-training approach for short text clustering[C]// Proceedings of the 4th Workshop on Representation Learning for NLP. Stroudsburg: ACL, 2019: 194-199.
- [25] HACOHEM-KERNER Y, MILLER D, YIGAL Y. The influence of preprocessing on text classification using a bag-of-words representation[J]. PLoS One, 2020, 15(5): e0232525.
- [26] RAKIB M R H, ZEH N, JANKOWSKA M, et al. Enhancement of short text clustering by iterative classification[C]// Proceedings of Natural Language Processing and Information Systems: 25th International Conference on Applications of Natural Language to Information Systems. Cham: Springer, 2020:105-117.
- [27] ZHANG D, NAN F, WEI X, et al. Supporting clustering with contrastive learning[C]// Proceedings of the 2021 Conference of the North American Chapter of the Association for Computational Linguistics. Stroudsburg: ACL, 2021: 5419-5430.
- [28] KAMTHAWEE K, UDOMCHAROENCHAIRIT C, NUTANONG S. MIST: mutual information maximization for short text clustering[C]// Proceedings of the 62nd Annual Meeting of the Association for Computational Linguistics. Stroudsburg: ACL, 2024: 11309-11324.
- [29] CUTURI M. Sinkhorn distances: Lightspeed computation of optimal transport[C]// Proceedings of the 27th International Conference on Neural Information Processing Systems. Red Hook, NY: Curran Associates, Inc, 2013: 2292 - 2300.
- [30] KOBAYASHI S. Contextual augmentation: Data augmentation by words with paradigmatic relations[C]// Proceedings of the 2018 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies. Stroudsburg: ACL, 2018: 452-457.
- [31] ASANO Y M, RUPPRECHT C, VEDALDI A. Self-labelling via simultaneous clustering and representation learning[C]// Proceedings of the 35th International Conference on Machine Learning. Online: ICLR Organizing Committee, 2020.
- [32] MAATEN L, HINTON G E. Visualizing data using t-SNE[J]. Journal of Machine Learning Research, 2008, 9(86): 2579-2605.
- [33] SU H, SHI W, KASAI J, et al. One embedder, any task: Instruction-finetuned text embeddings [C]// Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics. Stroudsburg: ACL, 2023: 1102-1121.
- [34] NI J, QU Chen, JING L, et al. Large Dual encoders are generalizable retrievers[C]// Proceedings of the 2022 Conference on Empirical Methods in Natural Language Processing. Stroudsburg: ACL, 2022:9844-9855
- [35] YIN J, WANG J. A model-based approach for text clustering with outlier detection[C]// Proceedings of the 2016 IEEE 32nd International Conference on Data Engineering. Washington, DC: IEEE Computer Society, 2016: 625-636.



- [36] PHAN X, NGUYEN L, HORIGUCHI S, et al. Learning to classify short and sparse text & web with hidden topics from large-scale data collections[C]// Proceedings of the 17th International Conference on World Wide Web. New York: ACM, 2008:91-100.
- [37] PAPADIMITRIOU C H, STEIGLITZ K. Combinatorial optimization: Algorithms and complexity [J]. IEEE Transactions on Acoustics, 32(6), 1984:1258-1259.
- [38] ZHENG X, HU M, LIU W, et al. Robust representation learning with reliable pseudo-labels generation via self-adaptive optimal transport for short text clustering[C]// Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics. Stroudsburg: ACL, 2023: 10493–10507.
- [39] NIE W, DENG L, LIU C B, et al. STSPL-SSC: Semi-Supervised few-shot short text clustering with semantic text similarity optimized pseudo-labels[C]// Proceedings of the 62nd Annual Meeting of the Association for Computational Linguistics. Stroudsburg: ACL, 2024: 12174-12185.

**This work is partially supported by** the National Natural Science Foundation of China (62473241,62376143).

**WANG Qianfei** born in 1999, M. S. candidate. His research interests include data mining.

**LI Yang**, born in 1988, Ph. D., associate professor. Her research interests include intelligent finance, natural language processing.

**LI Deyu**, born in 1965, Ph. D., professor. Her research interests include data mining.

**WANG Suge**, born in 1964, Ph. D., professor. Her research interests include natural language processing, text mining, sentiment analysis.

