

基于特征融合和对比学习的多视图文本聚类 算法研究

作者姓名_____俱丽莎_____

学校导师姓名、职称_____王卫卫 教授_____

企业导师姓名、职称_____毛俊峰 高工_____

申请学位类别_____应用统计 硕士_____

学校代码 10701
分 类 号 O213

学 号 21071212621
密 级 公开

西安电子科技大学

硕士学位论文

基于特征融合和对比学习的多视图文本聚类 算法研究

作者姓名：俱丽莎

领 域：应用统计

学位类别：应用统计硕士

学校导师姓名、职称：王卫卫 教授

企业导师姓名、职称：毛俊峰 高工

学 院：数学与统计学院

提交日期：2024 年 4 月

Research on Multi-view Text Clustering Based on Feature Fusion and Contrastive Learning

A thesis submitted to
XIDIAN UNIVERSITY
in partial fulfillment of the requirements
for the degree of Master
in Applied Statistics

By

Ju Lisha

Supervisor: Wang Weiwei Title: Professor

Supervisor: Mao Junfeng Title: Senior Engineer

April 2024

摘要

文本聚类是指在不需要预先对文本进行标注的前提下,将海量的文本数据分成多个有意义的类别,从而挖掘文本数据的内在联系。当前,文本数据的表达逐渐从单一的视图转向多视图发展。传统的单视图文本聚类方法无法满足多视图文本聚类的需要,如何充分利用多个文本视图中的互补信息提升聚类性能是文本聚类和挖掘的新挑战。本文研究面向多视图文本数据的聚类算法,主要成果如下:

首先,针对多视图文本聚类任务提出了一种深度学习策略。具体来说,该方法设计了一种新颖的自编码器网络结构学习多视图文本数据之间的共性特征,并基于自监督思想设计损失函数对学习到的特征进行簇分配。该策略通过设计一种融合机制有效地挖掘和整合了多个视图之间的互补信息。整个网络的训练流程分为两个阶段:在第一阶段,通过最小化重构损失函数对网络进行训练,提取数据中的重要特征;在第二阶段,利用聚类损失训练网络,实现对特征嵌入模块和最终聚类过程的联合优化。此外,相比于使用词频统计思想进行文本表示的传统文本聚类方法,本文引入了预训练语言模型实现词嵌入。在公共数据集上的实验结果验证了所提方法的有效性。

其次,提出了一种基于对比学习的多视图文本聚类模型。该模型集成了样本特征和聚类标签的一致性学习过程,根据相应的目标函数对网络进行训练。一致性特征学习部分通过对比文本数据在不同视图下的相似性和差异性对文本嵌入表示进行持续优化;一致性标签学习部分保证了语义簇在不同视图下的对应标签具有统一性,对簇标签进行动态协调。该模型还为每个视图搭建了深度特征提取器,避免了集体性特征学习过程中产生的视图私有信息损失。独立的特征提取策略能更好地适应不同视图下的差异,对文本中的原始信息进行最大程度的保留。实验结果表明,该模型在多个数据集上均取得了良好的聚类结果。

关键词: 文本聚类, 深度聚类, 对比学习, 多视图学习, 预训练语言模型

ABSTRACT

Text clustering aims to segment massive text data into several meaningful categories without pre-labeling, so as to mine the intrinsic connections between the data. Currently, expression of the text data gradually shifts from a single view to multiple views. Traditional single-view clustering methods are ineffective in dealing with the multi-view text data. How to make full use of the complementary information in multiple text views to improve the clustering performance is a great challenge. In this thesis, we consider multi-view text data clustering methods and the main results are as follow:

Firstly, a new deep learning method is proposed for multi-view text data clustering. To be specific, the method uses a newly designed auto-encoder to learn the common feature from the multi-view text data, and then uses a self-supervising loss to learn the cluster assignment from the learned features. The novelty is that we design a fusion mechanism so that the complementary information inherent in the multiple view data can be effectively exploited and integrated. The network is trained in two phases. In the first phase, the network is trained by minimizing the reconstruction loss to obtain important features from the data. In the second phase, the network is trained by minimizing the reconstruction loss and the clustering loss, so that the data embedding and the final clustering assignment are optimized jointly. Also note that, unlike the previous text clustering methods, which use word frequency statistics to represent text, we use a pre-trained language model to embed the multi-view text. Experimental results on public data sets show the effectiveness of our method.

Secondly, a contrastive learning approach is introduced to the multi-view text clustering task, aiming to optimize text representation by learning similarities and differences between samples, thus improving the discriminative nature of the feature and enabling the model to better distinguish similar and dissimilar instances in text data. To avoid the loss of private information in the views, deep feature extractors are built for each view separately in the proposed model to ensure better adaptation to the differences between views in the multi-view clustering task. After extracting the initial feature, specific objective functions using the idea of contrastive learning are designed, then a network module is built to achieve coherent learning, so that the multiple view features of the samples learn from

each other and dynamically coordinate the clustering labels. Experimental results show that our model achieves good clustering results on multiple datasets.

Keywords: Text Clustering, Deep Clustering, Contrastive Learning, Multiview learning, Pretrained Language Models

插图索引

图 2.1	自编码器基本结构示意图	8
图 2.2	Transformer 模型结构示意图	10
图 2.3	BERT 模型基本结构示意图	12
图 3.1	MTCF 模型结构图	17
图 3.2	多视图文本表征融合架构图	18
图 3.3	不同归一化方法的 BBCsport 聚类指标比较图	25
图 3.4	不同归一化方法的 BBC 聚类指标比较图	25
图 3.5	不同归一化方法的 Yahoo 聚类指标比较图	26
图 3.6	不同特征的 BBCsport 聚类指标对比图	27
图 3.7	不同特征的 BBC 聚类指标对比图	28
图 3.8	不同特征的 Yahoo 聚类指标对比图	29
图 3.9	BBC 数据集 T-SNE 可视化结果图	30
图 3.10	BBCsport 数据集 T-SNE 可视化结果图	31
图 3.11	Yahoo 数据集 T-SNE 可视化结果图	32
图 4.1	MCCL 模型结构示意图	35
图 4.2	不同维度特征的 BBCsport 聚类指标比较图	41
图 4.3	不同维度特征的 BBC 聚类指标比较图	41
图 4.4	不同维度特征的 Yahoo 聚类指标比较图	42
图 4.5	Yahoo 数据集不同维度特征的可视化结果	43
图 4.6	BBC 数据集不同维度特征的可视化结果	44
图 4.7	MCCL 与经典方法的 BBCsport 聚类指标对比图	46
图 4.8	MCCL 与经典方法的 BBC 聚类指标对比图	46
图 4.9	MCCL 与经典方法的 Yahoo 聚类指标对比图	46

表格索引

表 3.1	基于特征融合的多视图文本聚类算法表	22
表 3.2	数据集信息表	22
表 3.3	MTCF 模型特征维度设置表	24
表 3.4	不同归一化方式下的聚类性能表	25
表 3.5	不同特征的 BBCsport 聚类指标值比较表	27
表 3.6	不同特征的 BBC 聚类指标值比较表	28
表 3.7	不同特征的 Yahoo 聚类指标值比较表	28
表 3.8	模型有无语义聚类模块的聚类性能对比表	29
表 3.9	MTCF 与经典模型的聚类性能比较表	33
表 4.1	基于对比学习的多视图文本聚类算法表	38
表 4.2	MCCL 模型特征维度设置表	39
表 4.3	MCCL 模型在不同数据集上得到的聚类指标值	40
表 4.4	有无自编码器结构的聚类性能比较	40
表 4.5	MCCL 模型不同维度特征的聚类性能表	41
表 4.6	有无标签层的聚类性能对比	43
表 4.7	MCCL 与经典模型的聚类性能比较表	45

符号对照表

符号	符号名称
T	原始文本表示
X	训练样本
M	视图数量
k	聚类簇数
θ	模型初始参数
$\tilde{\theta}$	模型训练完成后的参数
φ	样本均值
σ	样本标准差
W	权重矩阵
τ	温度系数
α	t 分布自由度

缩略语对照表

缩略语	英文全称	中文对照
AE	Auto Encoder	自编码器
DEC	Deep Embedding Clustering	深度嵌入聚类
LDA	Latent Dirichlet Allocation	潜在狄利克雷分布
RNN	Recurrent Neural Network	循环神经网络
CNN	Convolutional Neural Network	卷积神经网络
MLM	MASK Language Model	掩蔽语言模型
NSP	Next Sentence Prediction	下一句预测
ACC	Accuracy	聚类准确度
NMI	Normalize Mutual Information	归一化互信息
ARI	Adjusted Rand Index	调整的兰德指数
LN	Layer Normalization	层归一化
MM	Min-Max Normalization	最大最小归一化
BN	Batch Normalization	批量归一化
ReLU	Rectified Linear Unit	线性整流单元
MLP	Multi-Layer Perceptron	多层感知机
T-SNE	t-Distributed Stochastic Neighbor Embedding	t 分布随机近邻嵌入
TF-IDF	Term Frequency-Inverse Document frequency	词频-逆文本频率

目 录

第一章 绪论.....	1
1.1 研究背景及意义.....	1
1.2 国内外研究现状.....	2
1.2.1 文本表示研究现状.....	2
1.2.2 文本聚类研究现状.....	3
1.2.3 多视图学习研究现状.....	5
1.3 论文研究内容及各章安排	5
1.3.1 研究内容	5
1.3.2 各章安排	6
第二章 相关理论	7
2.1 聚类相关理论知识.....	7
2.1.1 K-Means 算法.....	7
2.1.2 自编码器结构.....	7
2.1.3 DEC 算法.....	8
2.2 基于 Transformer 的预训练语言模型.....	10
2.2.1 Transformer 网络结构.....	10
2.2.2 BERT 模型.....	12
2.3 对比学习.....	13
2.4 算法性能评价指标.....	14
2.4.1 聚类准确率.....	14
2.4.2 归一化互信息.....	14
2.4.3 调整兰德系数.....	15
第三章 基于视图融合的多视图文本聚类模型	17
3.1 模型构建.....	17
3.1.1 多视图表征融合模块.....	17
3.1.2 语义聚类模块.....	21
3.2 模型数值实验.....	22
3.2.1 实验细节	24
3.2.2 BERT 文本嵌入作为聚类特征的性能.....	24
3.2.3 消融实验.....	27
3.2.4 可视化.....	30
3.2.5 与经典模型的比较.....	32
3.3 本章总结.....	33
第四章 基于对比学习的多视图文本聚类模型	35

4.1 模型理论研究.....	35
4.1.1 分层特征提取模块.....	36
4.1.2 一致性学习模块.....	37
4.2 模型实验研究.....	39
4.2.1 不同数据集上的实验结果.....	39
4.2.2 消融实验.....	40
4.2.3 可视化实验.....	43
4.2.4 与经典模型的比较.....	45
4.3 本章总结.....	47
第五章 总结与展望	49
5.1 本文工作总结.....	49
5.2 本文工作展望.....	50
参考文献.....	51

第一章 绪论

1.1 研究背景及意义

随着科技的进步和通信网络的发展,信息在人类社会的传递方式发生了翻天覆地的变化。正如十九世纪时第一根海底电缆架起了人类远距离沟通的桥梁,现如今手机等各类智能设备的广泛使用引发了新时代信息存在方式及交换方式的重大变革。智能设备既可以视为庞大信息网络中的直接传播者,又可看作是网络节点间信息的存储媒介,这直接导致了信息量级的指数级增长。于是,在当今这个数据爆炸、各类数据并行的时代,如何对现有的海量数据加以利用使其能更好的服务于大众成了学界和业界研究的新浪潮。

事物之间的联系是普遍存在的。在面对庞大且无序的未知数据流时,我们自然而然地会想到对数据进行划分并归类管理。而聚类就是数据科学领域中一种寻找数据内在联系的经典方法。与有监督的分类方法不同,聚类方法可以在不知道样本真实标签的情况下通过挖掘样本之间的相似性关系,将大量样本合理地划分成不同的语义簇。而多视图聚类方法则是传统聚类技术领域顺应时代变化以及数据形式变化发展而来的新兴分支。

多视图数据中的“视图”二字可以理解为样本在某一固定形式下所表现出的数据特征,样本在不同方面表现的信息特征都可以称为是该样本的不同视图。由于载体及传播方式的改变,信息逐渐由单一的视图表现向多样、立体的多视图表现转变。这为人们的日常生活和工作带来了极大的便利,使得我们在很多事情上都有了多样化的选择。比如在对门锁、手机等设备解锁时,我们不仅可以使传统的物理方式或者数字密码进行解锁,还可以使用人脸识别、指纹识别等多种生物解锁方式。在这一时代变化下,如何利用收集到的多视图信息对传统的聚类方法成为了具有挑战性的课题。

同一样本的不同视图特征具有一致性和特殊性。其一致性体现在不同视图都或多或少的包含了描述该样本主体特点的共性信息;特殊性体现在由于不同视图下的信息结构具有天然差异,因此每个视图都包含了特殊的独有信息。多视图聚类方法正是要合理利用视图间的一致性和差异性更好地引导数据集中的聚类簇的划分。举例来说,在实现具体的新闻聚类任务时,我们可以将网络新闻报道中的图片、标题、正文和文章下方的评论等多种形式的信息作为这篇文章的不同视图;在对某购物平台上的消费用户进行群体性划分时,可将用户在某购物平台上的搜索记录、点击记录和购买记录作为表现该用户购物风格的三个视图。多视图聚类方法不仅有望提高传统单视图聚类方法的性能,还能在日常的生产生活中带来极大的显示收益。

语言是人类世界的边界,我们在日常生活中始终无法脱离语言文字所凝聚成的基

石。随着神经网络迎来了再一次的发展高峰，自然语言处理、图像处理等深度学习技术现如今炙手可热。众多研究学者在自然语言处理领域勇攀高峰，研究如何使计算机能进一步理解和处理人类的语言文字。在我们日常生活中，绝大多数信息都是依靠语言文字进行传递和交换的。多视图文本聚类算法从理论性能的角度上来说，可以综合原始数据中的多个视图信息，打破单个视图对传统聚类方法性能的桎梏，减轻单个视图上噪声或异常值对最终聚类结果的干扰，整体提高算法的稳健性；而从实际应用的角度上来说，多视图文本聚类算法的应用场景广泛，可以在社交媒体分析、新闻整合、医学文本挖掘、知识图谱构建及舆情检测等多个场景下创造出一定的应用价值和经济价值。因此，在信息存在形式逐渐丰富化的时代背景下，学界和业界对多视图结构的文本数据进行的针对性聚类算法研究在理论和应用上都有着重大意义。

1.2 国内外研究现状

1.2.1 文本表示研究现状

由于计算机不能直接对语言文字这类非结构化数据进行处理，因此对自然语言进行处理首先要解决的是文本表征问题，即如何将文本数值化。文本表征方法经历了离散式表征、分布式表征和嵌入式表征三个阶段的发展。

离散型表征以独热编码（One-hot Encoding）为代表，独热编码使用一个维度为词表大小的向量对单个字词进行表示。如果这个词在词表中的位置为第 i 个，那么其对应的独热向量中第 i 维上的数值将被设置为 1，其余维度上的值均为 0。这种表征方式虽然能直观地反应出某个词是否出现，但无法对重要性不同的词语进行区分，因此难以对词义建模。

正如人类可以根据上下文完成选词填空这类联想式操作，John^[1]据此提出了一种分布式语义假设，该假设认为一个词的含义可以由所在位置的上下文分布进行表示。一系列文本分布式表征方法随后被提出，这些方法建立在对语料库进行统计的基础上，再根据奇异值分解等一系列变化得到的。最具代表性的为词频-逆文本频率方法（Term Frequency-Inverse Document Frequency, TF-IDF），TF-IDF 算法可以评估不同字词在文档集合或语料库中的重要程度。其中，词频指某一字词在当前文档全文中出现的频率；文本频率是指所有包含这个词的文本个数除以语料库中所有文本总数的比例，将这个比例值取倒数就可以得到对应的逆文本频率。如果某个词语在一篇文章中出现的频率较高但在其他文章中很少出现时，我们可以认为这个词是这篇文档独有的代表性词语，具有一定区分度。LSA^[2]基于概率生成模型的角度实现文本的表示，该方法首先构建了一个文本和词项的共现矩阵，再通过奇异值分解得到文本表示向量和词表示向量。LSA 将高维的文本向量近似地映射到了低维的潜在语义空间上，可以在一定

程度上减轻词语同义及多义的问题,但是训练得到的词向量一经确定后无法再次修改。

随着神经网络技术的发展,Bengio 等^[3]提出了神经网络语言模型(Neural Network Language Model, NNLM)。这使得我们在训练神经网络语言模型参数的同时,可以得到低维、稠密的嵌入式文本表征。Mikolov 等^[4]提出了基于 CBOW 模型(Continuous Bag Of Words, CBOW)及 Skip-gram 模型的 Word2vec 表征方法(Word Embeddings, Word2vec),完全基于词与词之间的共现信息实现了词向量的学习。Word2vec 词向量利用文本中不同词语在局部上下文中的共现信息作为自监督学习信号,增强了词向量的表达能力。Pennington 等^[5]在词嵌入表征中引入了隐式的矩阵分解方法,提出了 GloVe 模型(Global Vectors for Word Representation, GloVe)。然而无论是基于局部上下文预测的 Word2vec 模型,还是基于全局共现信息的 GloVe 模型,这类模型在本质上都依赖于单个字词在整个语料库中的共现上下文信息。因此当语料库固定时,训练得到的嵌入表征也保持不变。即对任意一个词,它的向量表示不随上下文的变化而变化。然而在自然语言中,一词多义是普遍存在的语言现象,同一个词在不同的上下文或语境下会引申出多种不同词义。

基于这一问题,学界涌现出了一系列基于“动态”嵌入式的文本表征研究。在这种动态的词表征方法中,词向量由当前所在的上下文计算得到,同一字词的词向量不再保持“静态”。Peters 等^[6]利用深度上下文相关的词向量思想提出了一种叫做 ELMo(Embeddings from Language Models, ELMo)的预训练模型,该模型能有效地处理一词多义问题。这为自动问答和文本蕴含等多项自然语言处理任务带来了显著的性能提升,同时被推广至多语言场景。OpenAI 利用大规模语料训练了一种生成式预训练(Generative PreTraining, GPT)模型^[7],提升了在自然语言理解任务中的性能。Devlin 等^[8]提出了双向预训练语言模型 BERT(Bidirectional Encoder Representations from Transformers, BERT)。BERT 模型充分挖掘了大规模无标注文本中丰富的语义信息,可以学习到具有良好性能的动态词向量。由于 BERT 模型具有优良性能,一系列基于此的改进模型被相继提出,最具代表性的有引入了动态掩码技术的 RoBERTa^[9]、利用了词向量因式分解的 ALBERT^[10]和具有生成器-判别器结构的 ELECTRA^[11]等。这些模型进一步发掘了文本的隐含表征,提升了在各类语言处理任务上的效果。

1.2.2 文本聚类研究现状

传统的文本聚类算法往往需要利用离散式表征或分布式表征方法将文本映射到向量空间中,再使用 K-Means^[12]等算法实现最终的分区划分。这类算法简单快速、操作便捷,但由于聚类过程基于迭代实现,因此对噪声敏感且结果不稳定。部分学者对 K-Means 算法进行了改进,产生了 K-Means++^[13]、K-Me-doids^[14]等一系列算法。虽然改进后的算法对噪声的鲁棒性增强,但也增加了时间复杂度高,运行速度慢。在此基

基础上,不少学者提出了融合聚类算法。为解决事先无法确定样本簇总数的情况,Fredana 等^[15]提出了一种基于 K-Means 的融合投票机制。Hu^[16]提出一种增强文本语义的文本聚类算法,虽然聚类性能有所提高,但这类融合算法在文本聚类时的合并操作是不可逆的。

由于主题凝聚了文章的中心思想,可以视为区分不同文本的天然特征,因此一部分学者对基于主题的文本聚类方法进行了研究。Hofmann 等^[17]在 LSA 的基础上提出了第一个完整意义上的概率主题模型--概率潜在语义分析模型。pLSA 模型 (probabilistic Latent Semantic Analysis, pLSA) 假设所有文档都具有主题分布,文本中的词可以看作是从该文主题对应的词分布中抽取得到的。该模型引入了概率统计的思想,避免了奇异值分解方法中的复杂计算。然而, pLSA 模型中的参数与特定文档相关,没有为不同主题赋予权重,有时会出现过拟合的情况。Blei 等^[18]提出了一种层次贝叶斯模型--潜在狄利克雷分配 (Latent Dirichlet Allocation, LDA)。该模型将参数看作随机变量,实现了彻底的“概率化”。Yin 等^[19]提出了一种狄利克雷多项式混合模型的短文本聚类方法 (collapsed Gibbs Sampling algorithm for the Dirichlet Multinomial Mixture model, GSDMM), 实现了对建模主题连贯性和一致性的提升。变分自编码器^[20] (Auto-Encoding Variational bayes, VAE) 使用标准高斯分布作为贝叶斯推断的主题先验分布,通过变分推断得到主题的变分后验分布。而混合自编码器模型^[21] (Mixture of Auto Encoders, MIXAE) 通过构造多个 VAE 的混合来实现主题分布的学习,但仍然无法刻画主题的混合分布情况。变分深度嵌入^[22] (Variational Deep Embedding, VaDE) 使用高斯混合模型^[23] (Gaussian Mixture Model, GMM) 对文本集合主题的混合先验概率分布进行了成功建模。这类基于主题模型的文本聚类方法具有较强可解释性,但往往存在训练时间长或对短文本的难以建模这类问题。

随着深度学习的风潮已席卷图像处理、自然语言处理等众多领域,一系列基于嵌入式表征的深度文本聚类技术因此产生。大多数深度文本聚类模型的特征提取器基于自编码器^[24] (Auto Encoder, AE) 结构组成,以无监督的方式对样本进行重构训练,从而压缩信息学习到低维的文本嵌入表示。深度嵌入聚类^[25] (Deep Embedding Clustering, DEC) 创新性的利用 t 分布构造了聚类辅助分布和目标分布,并使用 KL 散度^[26] (Kullback-Leibler divergence, KL) 函数同时对特征提取网络和聚类分区进行持续优化。融入数据结构信息的结构深度聚类网络^[27] (Structural Deep Clustering Network, SDCN) 利用数据本身特性和数据之间的结构信息来提高聚类效果。

Xu 等^[28]提出了一种基于自学习卷积神经网络框架,该文本聚类方法使用卷积神经网络学习特征表征,以重建聚类辅助目标。Hadifar 等^[29]在 Xu 的工作上融入了由 SIF 文本表征方法^[30] (Smooth Inverse Frequency, SIF) 得到的词嵌入,利基于自编码器的网络结构对特征进行提取和优化,取得了比原始的 STC 方法^[28]更好的聚类性能。

Guan 等^[31]提出了一种基于深度特征提取的文本聚类方法 DFTC (Deep Feature-based Text Clustering, DFTC), 探索了语言模型 NLM 和句子表示模型 InferSent^[32]作为深度文本特征提取器在文本聚类任务中的性能, 利用逻辑分类器结构设计了解释模型, 由此得到的解释结果可以对聚类结果的质量进行衡量。

1.2.3 多视图学习研究现状

多视图学习, 也称作多视角学习, 最先兴起于机器学习领域, 后广泛利用于图像处理、自然语言处理、生物医学等多个领域。多视图学习根据是否需要标签可分为有监督多视图学习方法和无监督多视图学习方法。其中, 无监督多视图学习方法可在没无外部标签对学习过程进行指导的情况下对不同视图中的底层信息进行充分挖掘和整合, 从而提高整体性能。

学者们提出了一系列的线性和非线性方法来关联不同视图下的数据, 学习多个视图中的丰富信息。最经典的多视图学习方法使用典型关联分析方法^[33] (Canonical Correlation Analysis, CCA) 最大化两个视图的线性投影之间的相关性。此外, 还使用核版本的典型关联分析方法^[34]最大化视图非线性函数之间的相关性。随着深度学习技术的发展, 还有一部分学者引入了深度神经网络来学习多个视图的灵活非线性表示^[35,36]。

除此之外, 经典的多视图学习还包括基于协同训练、图模型和多核学习等多种理论基础的方法。基于协同训练的多视图学习方法^[37]假设所有数据都可以从不同的角度进行分类, 使用部分有标签样本在不同视图下训练预测器并对无标签样本进行迭代标记, 通过交换样本训练标签提高分类精度。引入图信息的多视图学习方法^[38,39]从不同视图中学习基本的相似性矩阵或亲和矩阵, 并融合不同视图的表示。基于多核学习的多视图学习方法^[40,41]对不同视图构造不同基核, 再将多个核函数组合学习。

1.3 论文研究内容及各章安排

1.3.1 研究内容

本文主要研究面向多视图文本数据的具体模型结构和聚类损失函数设计, 具体内容如下:

(1) 网络结构的研究

经典的深度文本聚类模型仅仅利用样本的单一视图进行聚类, 其结构一般由特征提取器和聚类层两部分组成。这类模型难以充分利用多视图样本不同视图下的丰富信息, 可能会在多视图文本聚类任务中性能受限。因此, 本文将面向多视图文本数据, 研究多视图特征融合框架、分层式视图特征提取框架和相应的聚类层设置。在特征融合框架中, 利用深度神经网络进行多视图学习, 将所有视图下的有效信息综合成一种

能有效指导聚类过程的多视图特征。在分层式视图特征提取框架中，我们将对不同视图下的文本特征分别进行处理，从而可以得到多个层次的信息。

(2) 损失函数的研究

合理的损失函数设置能有效地引导网络模型的参数优化，从而提升最终任务的性能。在本文后续章节中设计的模型中，我们将分别利用 KL 散度和对比学习思想设计多视图文本聚类模型的损失函数。具体来说，将用 KL 散度建模数据分布和目标分布之间的差异，进一步优化网络模型和样本簇中心分布；基于对比学习的损失函数将使得同一样本在不同视图下表征的距离更加接近，从而学习到更具判别性的聚类特征，最终在数据集上实现良好的聚类分区。

1.3.2 各章安排

第一章主要介绍了多视图文本聚类研究背景及其意义，文本表征技术的发展、文本聚类技术和多视图学习的相关研究现状，并对本文的主要研究内容和章节安排进行了概述。

第二章将叙述 Transformer 及基于 Transformer 的预训练模型 BERT 的网络结构，并对聚类任务中常用的 K-Means 算法和自编码器结构进行了详细介绍。除此之外，还将对深度嵌入聚类方法 DEC 和对比学习的相关理论知识进行了概述。

第三章将实现一种基于视图融合的多视图文本聚类模型，我们基于自编码器结构设计了一种融合特征。为研究该方法的性能，我们随后在多个数据集上进行相关实验和分析。

第四章将介绍我们提出的基于对比学习的多视图文本聚类模型，我们利用对比学习思想设计了对应的模型结构和损失函数，并在实验中证明了各部分结构的有效性和模型整体的良好聚类性能。

第五章对本文内容进行了归纳总结，展望了我们在多视图文本聚类领域中未来可能的研究方向。

第二章 相关理论

在自然语言处理领域中，语言模型经过了长足的发展，成功地从多个角度对语句文字进行了数学建模。在本章中，我们介绍了聚类相关理论和经典的预训练语言模型进行了介绍并对多视图学习思想和对比学习思想进行叙述。为了能在后续实验中进行模型的性能比较，我们在本章末尾引入了具体的聚类算法评价指标。

2.1 聚类相关理论知识

2.1.1 K-Means 算法

K-Means 聚类算法又名 K 均值算法，是经典的聚类划分算法之一，在数据挖掘等众多领域均有广泛应用。使用 K-Means 方法时需要事先确定待划分数据集中簇的个数，使用欧几里得距离度量样本点与簇中心之间的距离，具体步骤如下：

步骤 1：在已知类别数为 k 的情况下，将从数据集中随机选取 k 个样本点作为初始的簇中心 $\{\mu_1, \mu_2, \dots, \mu_k\}$ ，对应的样本簇记为 $\{C_1, C_2, \dots, C_k\}$ 。

步骤 2：计算除簇中心以外的所有样本点到不同簇中心的距离 d ，并根据就近原则将样本点分配到距离最近的簇中心所对应的簇中，其中第 i 个样本点 x_i 与第 j 个簇中心 μ_j 之间的距离可计算为：

$$d(x_i, \mu_j) = \|x_i - \mu_j\|_2. \quad (2-1)$$

步骤 3：利用新的样本划分进行计算，即可实现对簇中心 $\{\mu_1, \mu_2, \dots, \mu_k\}$ 的更新，更新后的簇中心表示为 $\mu'_i (i=1, \dots, k)$ 。当所有簇中心在更新过程中均保持不变时，结束算法；否则返回步骤 2 继续进行迭代。具体的簇中心更新公式如下：

$$\mu'_i = \frac{1}{|C_i|} \sum_{x \in C_i} x. \quad (2-2)$$

K-Means 算法尝试找出使簇内平方误差函数值最小的划分，从而在最大化簇内样本的相似程度的同时对簇间样本的差异程度实现最大化。该算法具有使用实现简单、收敛速度快等优点，但对初始值较敏感，性能不太稳定。针对这些不足之处，众多学者提出了 K-Means++、K-Medoids 等一系列的改进算法。

2.1.2 自编码器结构

自编码器^[42]可以通过无监督的方式学习数据的有效表示，常用于数据降维、特征提取等领域。自编码器由对称的编码器和解码器两部分组成。自编码器的基本网络结构如下图所示：




图 2.1 自编码器基本结构示意图

原始数据 $x^n \in R^D (n=1,2,\dots,N)$ 将被编码器部分映射到 m 维的特征空间中，得到对应的编码 $z^n \in R^m$ 。在解码器部分，网络试图对由编码器得到的编码 z^n 进行重构，将第 n 个复原后的样本特征记为 $\hat{x}^n$ 。该过程可表示为：

$$\begin{cases} Z = f(W_e X + b_e) \\ X = g(W_d Z + b_d) \end{cases} \quad (2-3)$$

网络通过最小化重构损失来学习具体的参数，学习的目标函数如下：

$$L = \sum_{n=1}^N \|x^n - \hat{x}^n\|^2 \quad (2-4)$$

自编码器在原始数据上实现了数据压缩和复原，这种自监督的方式将强迫中间的隐藏变量 z^n 最大程度地携带信息，从而可以将学习到原始数据的有效表示。训练完成后的自编码器一般只保留编码器部分作为后续模型的输入。自编码器根据具体的网络实施细节的不同，还可以细分为稀疏自编码器^[43]、变分自编码器^[44]和降噪编码器^[45]等。本文将利用自编码器结构对多个视图的文本特征进行提取和融合处理，搭建性能优良的多视图文本聚类网络模型。

2.1.3 DEC 算法

DEC 是一种基于 K-Means 和自编码器结构实现的深度聚类方法。在利用 K-Means 聚类方法对簇中心进行初始化后，该算法将在优化特征学习网络的同时持续对簇中心

进行更新。这种通过构造辅助分布构造损失函数的方法将无监督的聚类任务转换为了伪监督学习，使其学习到了更好的特征嵌入和聚类分区。

现有样本 $i \in \{1, \dots, N\}$ ，这些样本所属的样本簇 $j \in \{1, \dots, K\}$ ，我们将样本簇对应的簇中心集合记为 $U = \{\mu_j, j=1, \dots, K\}$ 。其中，样本 i 被分配到第 j 个簇中的条件概率为 $P(j|i)$ ，当该条件概率分布服从学生 t 分布时，则有：

$$p(j|i) \propto \left(1 + \frac{\|z_i - \mu_j\|^2}{\alpha}\right)^{-\frac{\alpha+1}{2}}. \quad (2-5)$$

设样本是均匀采样的，那么样本的联合概率分布可表示为：

$$p(i, j) = \frac{p(j|i)}{N}. \quad (2-6)$$

我们构建辅助分布 q ，并使用联合分布 $q(i, j)$ 和 $p(i, j)$ 之间的 KL 散度来衡量辅助分布 q 和目标分布 p 之间的差异性。这两个分布之间的 KL 散度为：

$$E(q) = KL(q||p) = \frac{1}{N} \sum_{i=1}^N \sum_{j=1}^K q(j|i) \log \frac{q(j|i)}{p(j|i)}. \quad (2-7)$$

当目标分布给从样本 i 到簇 j 和从簇 j 到样本 i 都指派的都是高概率时，我们可以认为样本 i 到簇 j 的辅助分布的分配将被加强，因此有：

$$q(j|i) \propto p(j|i) \cdot p(i|j). \quad (2-8)$$

引入贝叶斯公式后可将式(2-8)可被表示为：

$$q(j|i) \propto \frac{p(j|i)^2}{\sum_{i=1}^N p(j|i)}. \quad (2-9)$$

最后我们利用每个簇的概率将辅助分布进行归一化，最终分布 q 可表示如下：

$$q(j|i) \propto \frac{p(j|i)^2 / \sum_{i=1}^N p(j'|i)}{\sum_{j=1}^K p(j'|i)^2 / \sum_{i=1}^N p(j|i)} \quad (2-10)$$

这种构造目标分布的方式在计算上满足了与软分配方法相匹配的灵活度,使得聚类分配被隐式地集成在软标签中,DEC 方法在多个实验集上均取得了较好的实验性能。该方法的不足之处在于聚类损失不能保证数据中局部结构的保持,从而可能导致嵌入空间被破坏。基于这一问题,学者们提出了 IDEC^[46]等改进算法,以期进一步提高算法稳定性。总的来说,DEC 算法因其创新性和良好的性能,是经典的深度聚类算法之一,在该研究领域保留有一席之地。

2.2 基于 Transformer 的预训练语言模型

2.2.1 Transformer 网络结构

在 Transformer^[47]出现之前,处理 Seq2Seq 任务时常用循环神经网络^[48](Recurrent Neural Network, RNN)模型和卷积神经网络^[49](Convolutional Neural Network, CNN)模型。但由于 RNN 模型是递归执行的,无法进行并行计算;CNN 模型只能通过感受野获得局部信息。基于以上模型的不足之处,Ashish Vaswani 等人与 2017 年提出了一种叫做 Transformer 的模型。Transformer 是基于注意力机制的网络模型,可解决在 Seq2Seq 任务中模型记忆长序列能力不足的问题。

Transformer 模型在原始自注意力模型的基础上融入了位置信息,使用了查询-键-值模式增强了向量的表达能力;除此之外,还使用了多头注意力模型解决了自注意力结果互斥的问题。模型分为编码器(Encoder)和解码器(Decoder)两个部分,每个部分都包含 6 个块。模型结构示意图如下所示:




图 2.2 Transformer 模型结构示意图

Encoder 部分包括多头自注意力模块和前馈神经网络两个模块。首先，模型对输入进行嵌入，得到初始词向量 E_0 。为了利用词句中天然的语序信息，作者改进了原始的自注意力模型，考虑将序列中每个 token 的位置信息融入初始的词向量。获得位置信息的常用方法有位置嵌入和位置编码两种。前者是为每一个绝对位置赋予一个性质良好的向量表示，比如使用一个和初始词向量维度一样的二进制向量来表示每个位置。后者利用周期函数将位置索引值映射到向量上，使得编码值既可以表示 token 的绝对位置，也可以表示其相对位置。序列中第 t 个位置的第 i 维值 PE_t^i 的具体公式如下：

$$PE_t^i = \begin{cases} \sin(t/10000^{i/d}), & i = 2k \\ \cos(t/10000^{i-1/d}), & \text{其它} \end{cases} \quad (2-11)$$

最终得到的词嵌入 E 为：

$$E = E_0 + PE. \quad (2-12)$$

随后，词嵌入 E 将被注入多头自注意力模块。在这个过程中将使用不同的参数矩阵对原始的嵌入向量进行线性变换，从而让不同的变换结果 Q, K, V 分别承担查询、键和值三种不同角色。具体的变换如下：

$$\begin{cases} Q = W_q E \\ K = W_k E \\ V = W_v E \end{cases} \quad (2-13)$$

自注意力矩阵由查询矩阵 Q 、键矩阵 K 、值矩阵 V 经 Softmax 操作计算得到，在式(2-14)中我们还使用了键矩阵 K 的维度 d_k 作为缩放因子：

$$Attention(Q, K, V) = \text{Softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V. \quad (2-14)$$

由于自注意力结果之间是互斥的，一个输入无法同时关注多个输入，即同时为这些输入赋予较大的注意力值。因此设置了多组映射矩阵，并将产生的多个输入向量拼接。这相当于集成了多个自注意力模型，可以理解为不同的注意力头可以抽取不同类型的特征，将大大增强模型的最终效果。

为了增强模型的表示能力，在获得由多头自注意力模块处理的新输入后要经过一

个前馈神经网络模块，在具体的实现上，还使用了残差连接、层归一化等神经网络常用优化方法。由于默认使用的激活函数为 ReLU，因此激活值恒大于等于 0，在前馈神经网络上进行的操作可表示为：

$$FFN(x) = \max(0, xW_1 + b_1)W_2 + b_2. \quad (2-15)$$

Decoder 部分有三个部分，包含了两个多头自注意模块和一个前馈神经网络模块。与 Encoder 不同的是这部分的第一个多头自注意力模块是使用了掩码机制的，通过对编码器的输入进行部分掩码来模拟数据之间的内在联系。再经由第二个多头自注意力模块和最后一个前馈神经网络模块处理后，还需要将数据输入最后一个线性层，经 Softmax 处理后获得最终的概率分布。

2.2.2 BERT 模型

由于 Transformer 模型具有优良的表现，随后学界涌现了一系列基于 Transformer 架构的预训练模型，BERT 就是其中之一。BERT 模型的全称为 Bidirectional Encoder Representation from Transformers，译为基于 Transformer 的双向编码表示模型。BERT 模型一经发表，便在多个 NLP 任务中取得了 SOTA 表现。

从结构上来说，BERT 模型是基于 Transformer 的 Encoder 实现的，在原论文中分别使用了 12 层和 24 层的编码器块来堆叠模型。其中，12 层的是 BERT 模型的 base 版本，24 层的是模型的 Large 版本。BERT 模型会将输入的文本先映射为 Token，再由词向量、块向量和位置向量之和组成具体的输入表示。块向量是针对句对文本而言的，位置向量则是编码每个词的绝对位置。模型结构示意图如下所示：




图 2.3 BERT 模型基本结构示意图

BERT 模型基于自编码的预训练任务进行训练。两个预训练任务分别是掩码语言模型任务 MLM 和下一个句子预测任务 NSP。掩码语言模型任务是从原文中随机选取全文的固定比率的字词对其进行掩码操作。具体来说,执行掩码操作时有 80%的概率会将文本中的词进行掩码,有 10%的概率随机选词对其进行替换,还有 10%的概率保持原字词不变。随后结合上下文来对掩码位置的语义进行重构,并与原文进行对照,借此训练模型。通过这类“完形填空”式的任务,可以加强模型对深层语义的理解。对阅读理解、文本蕴含等下游任务来说,模型需要能对两段文本的关系进行建模,因此模型还引入了下一个句子预测任务。具体来说,该任务通过预测输入句对的顺序来构建两段文本之间的关联,通过利用 BERT 模型中的隐含层表示作为特征据此建立分类器来判断句对中的句 B 是否为句 A 的下一个句子。

BERT 具有几十种语言的预训练模型版本,在多种 NLP 任务中被广泛使用。通常,BERT 这类预训练模型的应用方式有特征提取和模型微调两种。特征提取是直接利用 BERT 双向地对文本进行建模,即对输入文本的特征进行提取,并将其应用于具体的下游任务。在语音检测^[50]和文本分类^[51,52]等有监督任务中,众多学者已成功实现了基于 BERT 模型的文本数据表示。与此同时,也有一小部分学者研究了 BERT 模型在文本聚类任务中进行文本表示的性能^[53,54],本文也将尝试基于 BERT 模型对样本多个视图下的文本进行特征提取。

2.3 对比学习

传统的有监督方法需要大量带有标签数据来保证模型的学习能力,数据标注费时费力。因此,以对比学习为代表的自监督学习方法受到了广泛的关注。人类不仅能从积极的信号中学习到知识,还能从对立面中获取补充信息,这种行为模式给学者们带来了启发。将输入数据映射到一个特征空间后,对比学习能根据样本是否属于同一类别构造正样本对和负样本对,并对正负样本对的相似特征和对立特征进行学习,从而构造一个特征表示模型。

由于对比学习具有堪比有监督学习方法的出色性能,计算机视觉领域涌现了 simCLR^[55]、MoCo^[56]、BYOL^[57]和 SimSiam^[58]等一系列经典基于对比学习的模型。随后,部分学者将对比学习思想迁移到了自然语言处理领域中的文本相似性计算、语义表示学习和语言模型预训练等多项任务中。SimCSE^[59] (Simple Contrastive Sentence Embedding Framework) 提出了一种可以用于学习通用的句字嵌入向量的对比学习框架。ConSERT^[60]基于对比学习思想对预训练模型进行微调,由此进行句子语义表示的迁移。而 ArcSCE^[61]利用对比学习思想从角度空间的两两对比和三元组对比的角度进行句子表示的学习。

对比学习方法在最大化正样本对之间相似度的同时将最小化负样本对之间的距

离。而在聚类任务中我们力求增大不同样本簇之间的差异的同时减小同一样本簇内样本的差异。对比学习思想与聚类任务的目标不谋而合，因此在文本聚类任务中使用对比学习思想有利于学习到理想的样本空间表示，从而可以改进最终的聚类效果^[62]。

2.4 算法性能评价指标

本文选用了三种聚类算法中最常用的指标，分别是聚类准确率、归一化互信息和调整兰德系数，下面将对这些指标分别进行介绍。

2.4.1 聚类准确率

聚类准确率 ACC (Accuracy, ACC) 能直观体现单个样本的簇划分正确与否，是衡量簇标签分配正确比率的重要指标。由于在聚类任务中所划分的簇的对应标签是随机指定的，因此需要使用匈牙利算法来将预测的类别序号映射到真实的类别序号上，具体的计算公式如下：

$$ACC = \frac{\sum_{i=1}^n \sigma(p_i, \text{map}(q_i))}{n}, \quad (2-16)$$

其中 n 是样本总数， q_i 为第 i 个样本 x_i 通过聚类算法得到的预测簇标签， $\text{map}(q_i)$ 表示将预测簇标签与真实簇标签进行最优匹配的一个映射， p_i 为样本 x_i 对应的真实簇标签， $\sigma(\cdot)$ 为如下的示性函数：

$$\sigma(p_i, \text{map}(q_i)) = \begin{cases} 1, & \text{map}(q_i) = p_i \\ 0, & \text{map}(q_i) \neq p_i \end{cases}. \quad (2-17)$$

聚类准确率的最大值为 1，最小值为 0。当聚类准确率越高时，表示簇类别预测正确的样本占样本总数的比例越高，反之则越低。

2.4.2 归一化互信息

互信息是表示两个变量的关联程度，互信息 (Normalize Mutual Information, NMI) 是信息论里一种有用的信息度量，它可以看成是一个随机变量中包含的关于另一个随机变量的信息量，可以表示两个变量之间的关联程度。归一化互信息则是将互信息进行归一化后缩放得到的。

假设预测的聚类结果为 $\tilde{C} = \{C_i\}_{i=1}^{\tilde{c}}$ ，真实标签为 $C = \{C_j\}_{j=1}^c$ ，NMI 的计算公式如下：

$$NMI(C, \tilde{C}) \cong \frac{\sum_{i=1}^{\tilde{c}} \sum_{j=1}^c |\tilde{C}_i \cap C_j| \log \frac{n |\tilde{C}_i \cap C_j|}{|\tilde{C}_i| |C_j|}}{\sqrt{(\sum_{i=1}^{\tilde{c}} |\tilde{C}_i| \log \frac{|\tilde{C}_i|}{n}) (\sum_{j=1}^c |C_j| \log \frac{|C_j|}{n})}}. \quad (2-18)$$

归一化互信息可以衡量聚类结果与真实样本分布的相似程度。分子表示聚类簇和真实标签之间的互信息，分母表示由真实类别分布的熵和预测簇的熵组成的归一化系数。NMI 最大为 1，最小为 0。当指标值为 1 时，表示聚类结果与实际分布完全匹配；当值为 0 时，表明聚类结果完全是随机散布的。NMI 值越大，表示聚类效果越好。

2.4.3 调整兰德系数

调整兰德指数 (Adjusted Rand Index, ARI) 是通过计算在聚类结果和真实标签中被分配在相同或不同簇的样本对个数得到的外部指标，假设 $n_{ij} = |\tilde{C}_i \cap C_j|$ ， $a_i = \sum_{j=1}^c n_{ij}$ ， $b_j = \sum_{i=1}^{\tilde{c}} n_{ij}$ ， $i = \{1, 2, \dots, \tilde{c}\}$ ， $j = \{1, 2, \dots, c\}$ ，计算公式如下：

$$ARI(C, \tilde{C}) = \frac{\sum_{ij} \binom{n_{ij}}{2} - \left[\sum_i \binom{a_i}{2} \sum_j \binom{b_j}{2} \right] / \binom{n}{2}}{\frac{1}{2} \left[\sum_i \binom{a_i}{2} + \sum_j \binom{b_j}{2} \right] - \left[\sum_i \binom{a_i}{2} \sum_j \binom{b_j}{2} \right] / \binom{n}{2}}. \quad (2-19)$$

调整兰德系数 ARI 的取值为 $[-1, 1]$ ，是通过计算两个数据分布之间的相似度对聚类结果进行评估的，可以反映两种划分的重叠程度。值越大意味着聚类结果与真实情况越吻合。ARI 值为负数代表聚类结果十分不理想，而值越接近于 1 则表示聚类结果越好。

第三章 基于视图融合的多视图文本聚类模型

在日常生活中，为方便人们阅读，大多数文本都有着天然的格式结构，比如：新闻文本通常由标题和正文两部分组成，判决文书一般由首部、主文、判决结果和尾部四部分组成。这些不同的组织部分包含了不同层次的信息，层层递进且相辅相成，可以视为是样本的不同文本视图。在本章中，我们将利用上一章中介绍的聚类相关基础知识来搭建一种文本多视图特征融合框架，并将其集成至具体的聚类算法中，以期获得最终聚类性能的提升。

3.1 模型构建

由于目前很少有文本聚类算法考虑利用文本的多个视图对最终的聚类过程进行指导，因此我们尝试将多个文本视图的特征融合生成性质良好的综合性特征，并据此提出了一种基于特征融合的多视图文本聚类模型（Multi-view Text Clustering model based on Feature fusion, MTCF）。MTCF 模型整体结构示意图如下所示：




图 3.1 MTCF 模型结构图

如图 3.1 所示，MTCF 模型由多视图表征融合模块和语义聚类模块两部分组成。在多视图表征融合模块中，我们首先输入样本多个视图下的原始文本，在通过 BERT 模型提取初始特征后，利用表征融合网络对多个视图下的特征进行非线性表示学习。在语义聚类模块中，我们以伪监督的方式利用前一模块中生成的特征对网络进行微调训练，并利用最终得到的融合特征进行判别式聚类。在本章后续小节中，我们将分别对两个模块进行详细的叙述。

3.1.1 多视图表征融合模块

我们将使用预训练好的语言模型 BERT 得到各个视图下的文本嵌入表征。设现有 n 个样本，每个样本都有 M 个视图，所有样本在第 m 个视图下的文本可表示为 $t_1^m, t_2^m, \dots, t_n^m$ 。由于 BERT 模型的最终输出与其预训练任务极为相关，因此我们选取 BERT 模型第十一层的输出作为每个视图下的初始表征 V^m 。为增强后续算法的稳定性，我们将为初始表征进行归一化处理，由此即可得到样本 T^m 在第 m 个视图下的单视图表征 X^m ，具体过程如下式所示：

$$\begin{cases} V^m = \text{BERT}(T^m) \\ X^m = \text{Normlization}(V^m) \end{cases} \quad (3-1)$$

在获得了单个文本视图的表征后，我们需要将 M 个视图特征融合为一个新的文本表征。为了能合理地综合不同视图中携带的文本特性信息，我们提出了一种多视图文本表征融合架构。该融合架构基于自编码器结构，由编码器和解码器两部分组成，其结构如下图所示：




图 3.2 多视图文本表征融合架构图

我们为每个视图下的表征分别搭建了编码器,每个编码器都由两个密集连接块组成,而每个密集连接块中都有全连接层、正则化层和激活层三部分。将单视图特征 X^m 输入对应编码器的第一个密集连接块时,首先将在全连接层中进行线性变化,接着特征被输入至正则化层中进行批量归一化操作,最后视图特征将被输入使用 ReLU 激活函数的激活层中,即可得到该视图的低层特征 E_l^m 。在第一个子块中的计算如式(3-2)所示:

$$\begin{cases} \tilde{X}^m = BN(W_1 X^m + b_1) \\ E_l^m = ReLu(\tilde{X}^m) \end{cases} \quad (3-2)$$

将所有视图的低层特征进行拼接后可得到样本的低层拼接向量 E_l :

$$E_l = [E_l^1, E_l^2, \dots, E_l^M]. \quad (3-3)$$

接着我们将所有低层特征 $E_l^m (m=1, 2, \dots, M)$ 输入到视图对应编码器的第二个密集连接块中,在特征依次通过三个只有维度设置不同的子层处理后,我们将得到视图的高层特征,第 m 个视图的高层特征可记为 E_h^m :

$$\begin{cases} \hat{X}^m = BN(W_1 E_l^m + b_1) \\ E_h^m = ReLu(\hat{X}^m) \end{cases} \quad (3-4)$$

与低层拼接向量的逻辑类似,我们将根据式(3-5)将不同视图的高层特征继续进行拼接,由此可得到高层拼接向量 E_h :

$$E_h = [E_h^1, E_h^2, \dots, E_h^M]. \quad (3-5)$$

由于得到的低层拼接向量和高层拼接向量的维度较大且不一致,因此我们将其分别输入线性层中保证两种拼接向量具有相同的维度,并使用 ReLU 激活函数增强其表示能力:

$$\begin{cases} E'_l = ReLu(W_2 E_l + b_2) \\ E'_h = ReLu(W_3 E_h + b_3) \end{cases} \quad (3-6)$$

此时, 视图低层特征 E'_l 和高层特征 E'_h 包含了样本在所有视图下的不同层次信息, 因此我们考虑串联原始特征、低层特征和高层特征这三种不同层次的特征。这在一定程度上能综合所有特征中的丰富信息, 并对得到特征的最终性能进行增强。我们把所有拼接向量和单视图特征根据下式进行串联得到向量 E' :

$$E' = [X, E'_l, E'_h]. \quad (3-7)$$

我们为串联后的综合向量 E' 设置了一个瓶颈层(Bottleneck Layer), 在瓶颈层中将综合向量中的信息进行进一步压缩, 在该层中进行的操作如下所示:

$$\begin{aligned} E'' &= BN(W_4 E' + b_4) \\ E &= ReLu(E'') \end{aligned} \quad (3-8)$$

编码器输出的融合向量 E 将在后续训练中作为解码器的输入。解码器的结构与编码器类似, 每个对应的视图也由两个密集块组成。为了避免模型过拟合, 我们在解码器中额外设置了失活层。在单个密集块中进行的操作可表示为:

$$\begin{cases} V' = BN(W'E + b') \\ V = Dropout(ReLu(V')) \end{cases} \quad (3-9)$$

在融合向量 E 经过第 m 个视图下对应解码器的两个密集块处理后, 我们即可得到复原后的单视图特征 $V^m (m=1, 2, \dots, M)$ 。在这个融合架构中, 我们的目标是使用编码器从多个视图中创建一个新的多视图文本表征, 并使用解码器将得到的多视图文本表征尽量还原为单个视图特征, 以便编码器能学习到最优的文本特征编码。我们将所有视图下的编码器输入特征拼接为 X , 将解码器输出的不同视图下的复原特征拼接为 V , 并使用 L2 损失衡量两者之间的差距, 训练中具体的目标函数如下式所示:

$$L_f = \|X - V\|_2^2. \quad (3-10)$$

在对搭建的自编码器的完成预训练后, 我们将删除掉解码器部分, 仅对编码器结构进行保留, 此时瓶颈层的输出向量即为得到的初始多视图融合文本特征。在下一模块中, 我们将设计目标函数对解码器部分的网络参数进行微调, 从而进一步优化多视图融合特征的性能。

3.1.2 语义聚类模块

我们从 DEC 方法中得到启发, 在对多视图文本特征融合架构完成预训练后, 在保留的编码器结构后加入聚类网络层, 搭建端对端形式的多视图聚类模型结构, 并同时对这两部分进行优化。

我们将该模块的聚类损失定义为式 (3-11) 中的 KL 散度函数, 并据此对网络进行训练。语义聚类模块的训练损失函数为:

$$L_c = \text{KL}(Q \| P) = \sum_i \sum_j q_{ij} \log \frac{q_{ij}}{p_{ij}}, \quad (3-11)$$

其中 Q 为辅助分布, P 可视为是对分布 Q 进行软分配的概率分布。概率分布 P 服从自由度为 α 的 t 分布, 条件概率 p_{ij} 可由多视图融合特征 z_i 和簇中心 μ_j 之间的相似度计算得到。 q_{ij} 和 p_{ij} 分别可由下式进行计算:

$$p_{ij} = \frac{\left(1 + \|z_i - \mu_j\|^2 / \alpha\right)^{-\frac{\alpha+1}{2}}}{\sum_j \left(1 + \|z_i - \mu_j\|^2 / \alpha\right)^{-\frac{\alpha+1}{2}}}, \quad (3-12)$$

$$q_{ij} = \frac{p_{ij}^2 / \sum_i p_{ij}}{\sum_j \left(p_{ij}^2 / \sum_i p_{ij}\right)}. \quad (3-13)$$

在具体的优化阶段, 我们使用小批量随机梯度下降和反向传播来优化样本簇中心和网络参数。我们将自由度设置为 1, 多视图融合特征和簇中心的梯度可计算如下:

$$\frac{\partial L}{\partial z_i} = \frac{\alpha+1}{\alpha} \sum_j \left(1 + \frac{\|z_i - \mu_j\|^2}{\alpha}\right)^{-1} (q_{ij} - p_{ij})(z_i - \mu_j), \quad (3-14)$$

$$\frac{\partial L}{\partial \mu_j} = \frac{\alpha+1}{\alpha} \sum_i \left(1 + \frac{\|z_i - \mu_j\|^2}{\alpha}\right)^{-1} (q_{ij} - p_{ij})(z_i - \mu_j). \quad (3-15)$$

由于条件概率 p_{ij} 表示第 i 个样本属于第 j 个样本簇的概率, 因此在完成参数的训

练后，第 i 个样本最终的簇划分可由下式得到：

$$y_i = \underset{j}{\operatorname{argmax}} (p_{ij}). \quad (3-16)$$

综上所述，我们可以得到模型算法如下表所示：

表 3.1 基于视图融合的多视图文本聚类算法

算法 4.1： 基于视图融合的多视图文本聚类算法

输入： 多视图文本数据集 $\{T^m\}$ ；预训练 epoch 数 Ep_1 ；聚类 epoch 数 Ep_2 ；批次大小

输出： 训练好的模型；聚类结果

获取初始文本表征 $\{X^m\}$ ： $X^m = \text{Normlization}(\text{BERT}(T^m))$ ；

for $i=1$ to Ep_1 **do**

 生成复原向量 V^m ： $V^m = g_\theta(f_\theta(X^m))$ ；

 对多视图特征融合架构进行预训练： $L_f = \sum \|X^m - V^m\|_2^2$ ；

$i = i + 1$ ；

for $j=1$ to Ep_2 **do**

 获取特征融合向量 E ： $E = f_\theta(X^m)$ ；

 构造损失函数微调融合架构并训练聚类层： $L_c = KL(P \| Q) = \sum_i \sum_j p_{ij} \log p_{ij} / q_{ij}$ ；

$j = j + 1$ ；

end

使用训练完成的模型得到样本预测标签，计算聚类结果(ACC、ARI、NMI)；

输出聚类结果；

3.2 模型数值实验

本文中的所有实验是在 BBCsport、BBC 和 Yahoo 三个多视图文本数据集上完成的，所有数据集的详细信息如下表所示：

表 3.2 数据集信息表

数据集	类别数	视图数量	样本数量
BBCsport	5	2	737
BBC	5	2	2225
Yahoo	6	2	5255

BBCsport 和 BBC 是新闻数据集，分别具有标题和正文两个视图。BBCsport 数据集中包含橄榄球、板球、足球、网球及运动员五个类别的 737 个新闻样本。BBC 数据集中共有 2225 个样本，可根据新闻领域的不同分为商业、娱乐、政治、运动及科技五个类别。Yahoo 是从在线问答中收集到的大型数据集，包含问题和最佳回答两个文本视图。由于 Yahoo 原始数据集包含将近十六万条数据，因此我们从科学数学、电脑互联网、运动、英语娱乐、家庭关系及政治政策六个类别中选择了部分样本组建了 Yahoo 数据集。

由于 BERT 模型输出的特征是数据集中某段文本在某一视图下所有 token 的嵌入特征，为获取文本表征，我们将采用平均特征方法作为特征综合策略。设由一段文本中由第 i 个 token 得到的 BERT 特征为 $h_i = [h_{i1}, h_{i2}, \dots, h_{id}]$ ，则该文本对应的样本特征的第 k 维可表示为：

$$L = h[k] = \frac{1}{n} \sum_{i=1}^n h_{ik}. \quad (3-17)$$

合理的归一化方法有利于提高模型的鲁棒性和优化的收敛速度。在获得单个文本不同视图下的 BERT 嵌入后，我们将使用不同的归一化策略对单视图嵌入进行处理，分别为恒等归一化、层归一化和最大最小值归一化，下面将对这三种不同的归一化方法分别进行介绍。

我们将如下所示的恒等归一化方法作为归一化的基线方法：

$$f(h) = h. \quad (3-18)$$

层归一化方法可根据每一维特征的均值调整为 0，方差调整为 1。其中， ϕ_i 为样本第 i 维特征的均值， σ_i 为样本第 i 维特征的标准差，用公式可表示为：

$$\bar{h}_i = \frac{h_i - \phi_i}{\sigma_i}. \quad (3-19)$$

最大最小归一化可以利用数据的极大值和极小值将原始数据映射到[0,1]区间中，具体公式如下所示：

$$\bar{h}_i = \frac{h_i - \min_d(h_{id})}{\max_d(h_{id}) - \min_d(h_{id})}. \quad (3-20)$$

3.2.1 实验细节

由于 BBCsport 数据集中的样本量较少,我们将该数据集下的 `batch_size` 设置为 64。在其余两个数据集上,我们将 `batch_size` 统一设置为 128。出于对数据集各个视图下平均文本长度等多个不同因素的考虑,我们将 BBCsport 数据集和 BBC 数据集标题视图的文本长度设置为 10,正文视图的文本长度设置为 64。与此同时,Yahoo 数据集上的问题视图的文本视图长度设置为 32,答案视图的文本视图长度设置为 64。

在多视图特征融合架构的预训练过程中,我们将训练 `epoch` 数设置为 20,并使用随机梯度下降法进行优化,这个训练过程的学习率设置为 0.1。为了避免模型出现过拟合的情况,我们采用 dropout 策略,将解码器的 dropout 率设置为 0.2,即以 20% 的概率随机对神经元进行丢弃。

聚类环节的训练 `epoch` 最大值设置为 1000,优化器的学习率设置为 0.01,Momentum 设置为 0.5;聚类模块中的收敛边界设置为样本总数的 0.1%,每训练 50 个聚类 `epoch` 后检查一次,如果标签发生变化的样本总数小于收敛边界则停止模型训练,并进行最终的聚类指标值计算。

表 3.3 MTCF 模型特征维度设置表

特征名称	特征维度
单视图 BERT 特征	768
低层拼接特征	100
高层拼接特征	100
多视图融合特征	5

MTCF 模型中不同层次的特征维度设置如表 3.2 所示。我们所使用的 BERT 语言模型输出特征的固定维度为 768,因此我们得到的样本单视图文本表征的维度也为 768。低层拼接特征和高层拼接特征的维度均设置为 100。为进一步压缩信息并降维,我们将多视图融合特征的维度设置为 5。

3.2.2 BERT 文本嵌入作为聚类特征的性能

归一化是机器学习及深度学习领域中常用的数据预处理方法,本质上是一种线性变化。合理的数据归一化方法有利于提高 k-means 等基于距离度量类算法的稳定性,也可以加快算法或模型的收敛速度。我们将使用不同数据集的单视图特征和多视图混合特征来验证不同的归一化方法对最终聚类性能的影响,最终选择出适用性最强的归一化方法。

表 3.4 不同归一化方式下的聚类性能表

datasets	BBCsport			BBC			Yahoo		
metrics	ACC	NMI	ARI	ACC	NMI	ARI	ACC	NMI	ARI
View1+I+KM	26.68	1.89	1.29	35.99	3.62	2.12	24.05	3.42	1.48
View1+LN+KM	27.41	3.08	1.58	41.01	20.40	16.00	27.95	8.57	3.44
View1+MM+KM	27.41	3.14	1.62	40.72	19.72	15.59	26.00	5.43	1.85
View2+I+KM	56.07	36.22	25.93	68.79	59.25	51.65	27.36	4.86	9.50
View2+LN+KM	56.75	40.03	25.85	69.12	59.76	51.78	31.15	13.49	7.15
View2+MM+KM	56.17	41.99	24.46	67.69	60.58	53.12	27.65	10.24	5.53
MTCF+I	66.77	53.43	49.70	76.27	65.24	61.51	31.55	13.29	7.89
MTCF+LN	67.62	53.79	44.45	76.86	66.43	61.80	40.40	21.37	15.95
MTCF+MM	41.66	22.36	13.06	48.65	37.33	27.92	30.34	12.71	8.97




图 3.3 不同归一化方法的 BBCsport 聚类指标比较图




图 3.4 不同归一化方法的 BBC 聚类指标比较图




图 3.5 不同归一化方法的 Yahoo 聚类指标比较图

表 3.4 和图 3.2~3.5 展示了在三个不同数据集上的最终聚类性能，其中，I、LN 和 MM 分别表示恒等归一化、层归一化和最大最小值特征归一化，KM 表示 K-Means 方法，我们在数据集的单视图文本上使用了这种经典的聚类方法进行聚类分区。从中可以得到：

1.不同视图上由于天然结构的差异所携带信息量各不相同。BBC 数据集和 BBCsport 数据集的视图一都为标题视图，视图二为正文视图。这两个数据集的正文视图上可以引导簇划分的信息质量均高于标题视图所代表的视图一。而 Yahoo 数据集的两个单视图特征在聚类指标上的差异相差不大，这表示该数据集中问题视图和答案视图的质量较为平均，虽然文本结构不同，但都含有一定的类别信息。

2.在单个视图特征上，LN 和 MM 这两种数据预处理方式对提高最终聚类结果的性能均有所帮助。相较之下 LN 归一化的对数据的处理效果略好于 MM 归一化。在 BBC 数据集的单视图特征上，与恒等归一化相比，三种聚类指标最高提升了 5.02、16.78 和 13.88 个百分点。在 BBCsport 数据集的单视图特征上，ACC、NMI 和 ARI 最高提升了 0.73、5.77 和 0.33 个百分点。而在 Yahoo 数据集上，ACC、NMI 和 ARI 三种聚类效果指标最高提升了 3.9、8.63 和 1.96 个百分点。

3.MTCF 方法融合了多个视图中的信息，在数据集上的性能明显好于单视图加 k-means 的组合聚类方法。层归一化搭配 MTCF 方法的表现最好，相比于恒等归一化方式，在三个数据集上的 ACC 指标平均提高了 3.43%，在 NMI 指标和 ARI 指标上平均提高了 3.21%和 1.03%。相比其他两个数据集，LN 归一化在 Yahoo 数据集上对聚类效果的提升效果最为明显，在三个指标上平均提升了 8.33 个百分点。我们在下文实验中将继续沿用 MTCF 搭配 LN 归一化这种最优设置进行后续的实验探索。

3.2.3 消融实验

在消融实验中，我们首先对视图融合框架的有效性进行验证。将只经过预训练但未经过后续微调的融合框架所得到的特征和直接拼接后进行平均得到的多视图拼接特征和所有单视图文本 BERT 特征进行对比。为了保证公平，将在所有特征上直接使用 K-Means 方法得到聚类结果。

表 3.5 不同特征的 BBCsport 聚类指标值

BBCsport			
	ACC(%)	ARI(%)	NMI(%)
View1+KM	26.68	1.89	1.30
View2+KM	57.07	36.22	26.93
View1+view2+KM	47.63	34.39	19.49
融合特征+KM	58.97	43.68	31.37




图 3.6 不同特征的 BBCsport 聚类指标比较图

由表 3.5 和图 3.6 可知，在这四种不同特征的 BBCsport 数据集聚类结果中，融合特征加 K-Means 的组合在所有聚类指标上均获得了最高值。其中，ACC 值为 58.97%，NMI 值为 43.68%，ARI 值为 31.37%。由视图二直接嵌入得到的 BERT 文本表征性能次之，由视图一得到的单视图特征的聚类表现最差，NMI 值和 ARI 值仅为 1.89% 和 1.30%。而简单拼接得到的多视图平均特征性能平平，此时该特征的两个聚类指标值虽然高于视图一的聚类性能，但低于由视图二特征得到的聚类指标值。可见，这种简单的特征融合方式并不能合理利用多个视图中的信息，反而会损失高质量视图中所携带的信息。

表 3.6 不同特征的 BBC 聚类指标值

BBC			
	ACC(%)	ARI(%)	NMI(%)
View1+KM	41.01	20.40	16.00
View2+KM	69.12	59.76	51.78
View1+view2+KM	68.81	56.31	53.34
融合特征+KM	71.74	57.66	53.91




图 3.7 不同特征的 BBC 聚类指标比较图

表 3.6 为四种特征在 BBC 数据集上的聚类指标值, 图 3.7 为对应的聚类性能值的可视化图, 从中我们可以得知: 在 BBC 数据集上, 融合特征的 ACC 指标数值为 71.74%, 比视图一单特征、视图二单特征和多视图组合特征的数值分别高出 30.73、2.62 及 2.83 个小数点; 融合特征的 NMI 指标数值为 57.66%, 略低于视图二上的单视图特征得到的指标; 在 ARI 指标上, 融合特征取得了 53.91% 的最高值, 足足比 ARI 值最低的视图一 BERT 特征高出 37.91%。

表 3.7 不同特征的 Yahoo 聚类指标值

Yahoo			
	ACC(%)	ARI(%)	NMI(%)
View1+KM	27.95	8.57	3.44
View2+KM	31.15	13.49	7.15
View1+view2+KM	29.97	18.29	8.72
融合特征+KM	34.20	19.10	10.08




图 3.8 不同特征的 Yahoo 聚类指标比较图

由上表和上图可知，四种特征在 Yahoo 数据集上的 ACC 指标最高值为 34.20%，NMI 指标最高为 19.10%，ARI 值为 10.08%，这些指标的最高值均为融合特征加 k-means 的组合方法所取得的。在所有数据中 ACC 指标的最低值为 27.95%，NMI 指标最低值为 8.57%，ARI 指标最低值为 3.44%。三种指标的最高值和最低值之间分别相差 6.25%、10.53%和 6.64%。与前两个数据集相比，由不同的特征方法得到的所有指标之间的差异相对较小。

综合来说，由 MFTC 模型中的多视图融合模块得到的融合特征在三个数据集上均表现出了优异性能。各项指标显著优于单视图特征的聚类性能和仅仅进行简单拼接的多视图平均特征，这足以证明该融合框架的有效性。值得注意的是，多视图平均特征在多个指标值上均低于利用单个优势视图进行聚类获得的指标值。这可以解释为不合理的多视图融合策略无法结合多个视图中包含的特有信息和公共信息，很可能造成单个视图特征中信息的损失，直接导致聚类性能的降低。

表 3.8 有无语义聚类模块的聚类性能对比

	BBCsport			BBC			Yahoo		
	ACC	NMI	ARI	ACC	NMI	ARI	ACC	NMI	ARI
优化前	58.97	43.68	31.37	71.74	57.66	53.91	34.20	19.10	10.08
优化后	67.62	53.79	44.45	76.86	66.43	61.80	40.39	21.37	15.95

由上表可知，在语义聚类模块中，我们通过使用 KL 散度作为损失函数同时对编码器和簇中心进行优化后，三个数据集上的聚类指标均有不同程度的提升。具体来说：在 BBCsport 数据集上，ACC 比优化前提高了 8.95 个百分点，NMI 提高了 10.11 个百

分点, ARI 提高了 13.08 个百分点; 在 BBC 数据集上, ACC 比初始化是提升了 5.12 个百分点, NMI 提升了 8.77 个百分点, ARI 提升了 7.89 个百分点; 在 Yahoo 数据集上, ACC 提升了 6.19 个百分点, NMI 提升了 2.27 个百分点, ARI 提升了 5.87 个百分点。由此可说明, 第二部分网络优化模型可以利用目标分布和当前分布之间的差别, 对自编码器的参数进行调整, 由此可以学习到性能更优的特征嵌入, 提高整体模型的最终性能。

3.2.4 可视化

T-SNE (t-Distributed Stochastic Neighbor Embedding, t-SNE) 方法可以基于 t 分布对高维数据进行降维的同时保留原始数据的局部结构, 是一种常用的降维方法。为能更直观地体现样本进行聚类的情况, 我们将使用 T-SNE 方法对不同特征进行可视化。在实验中主要选取了三种特征, 分别为单视图 BERT 嵌入特征、多视图平均 BERT 特征和由 MTFC 方法最终得到的多视图融合特征。图 3.9、图 3.10 和图 3.11 分别是我们在 BBC 数据集、BBCsport 数据集和 Yahoo 数据集上得到的聚类结果可视化图。




图 3.9 BBC 数据集上的 T-SNE 可视化结果图

图 3.9 中的(a)和(b)分别是 BBC 数据集上视图一和视图二的单视图文本的 BERT

嵌入特征,可以看出单视图特征上不通过的样本簇之间的分区模糊,其中由视图一得到的不同真实类别的嵌入特征尤其的交错混杂,难以区分。(c)中的多视图平均特征由于结合了两个视图中的信息,不同类别的特征分区相较单视图有所改善,但簇之间的分区仍不清晰。由(d)可知,使用我们提出的 MFTC 方法得到的多视图融合特征能合理地对本样本进行区分,不同簇之间的分界明显,簇内样本密集。




图 3.10 BBCsport 数据集上的 T-SNE 可视化结果

由图 3.10 可知,由于从标题视图中获得的特征信息不足以引导样本进行分区划分,因此(a)中属于不同真实簇的样本点混杂在一起,整体排布散乱。(b)和图(c)中分别由视图二特征和多视图平均特征引导的样本分布较为相似,仍没有表现出具有良好的分区。真实标签属于同一簇中的同色样本相比(a)中的更加集中,但所有簇之间互相连接,形成一整个块状。在由融合特征得到的(d)中,同色样本之间的距离进一步被压缩,真实簇之间的分界较为清晰,尤其是运动员、板球和足球三个样本簇之间的距离显著增大。因此,融合特征在四种特征的聚类性能中表现最佳。

由于 BBC 数据集和 BBCsport 数据集为新闻数据集,对应的两个视图均为标题视图和正文视图,两个视图中的信息相辅相成,所生成的融合特征最终的聚类性能都有着显著提升。




图 3.11 Yahoo 数据集上的 T-SNE 可视化结果

图 3.11 中的(a)、(b)、(c)和(d)分别为 Yahoo 数据集上的两种单视图特征、多视图平均特征和融合特征的 T-SNE 可视化图片。在图 3.11(a)和(b)的两个单视图特征中样本分区不明显，而与(a)相比，(b)上样本点排列更加紧凑。(c)中代表科学及数学类别的红色样本点与其余类别的样本点有一定区分度，但剩余五个类别的样本点仍然是一整个块区，彼此之间区分度不高。由(d)可知，多视图融合特征虽然使得多数样本点分布更加紧凑，但没能明显区分不同类别的样本点。这也佐证了表 3.7 中在 Yahoo 数据集上得到的数值实验结果，即相比基于其他特征，融合特征为最终的聚类结果带来了小幅度的性能提升。这可能由于该数据集上的两个视图分别为问题视图和答案视图，两个视图的语义特征有较大的差异，因此影响了融合特征的最终聚类性能。

3.2.5 与经典模型的比较

我们将 MTCF 方法与五种经典文本聚类方法进行对比，其中基线方法是 TF-IDF 特征加 K-Means 的组合方法，LDA 和 GSDMM 是主题建模类的文本聚类方法，而 STC 和 DFTC 则是基于神经网络模型的深度文本聚类方法。由于对比方法并未对不同天然

结构的文本进行区分,因此我们将继续保持前期实验中对不同数据集文本视图的长度设置,并将从多个视图中截取的文本合并为单个视图,对比方法中的参数均遵循原论文的最优设置。

表 3.9 MTCF 与经典模型的聚类性能比较

datasets	BBCsport			BBC			Yahoo		
metrics	ACC	NMI	ARI	ACC	NMI	ARI	ACC	NMI	ARI
Tf-idf+KM	58.25	46.51	28.29	48.14	39.06	20.06	32.93	18.24	11.82
LDA	41.22	15.27	11.73	40.30	15.32	10.92	24.66	12.94	10.25
GSDMM	52.18	33.74	27.45	67.54	46.68	46.15	37.84	23.98	19.18
STC	57.80	51.29	36.86	58.07	51.20	36.82	35.24	22.93	12.98
DFTC	61.67	39.06	29.52	70.63	58.96	56.42	39.45	24.34	19.92
MTCF(ours)	67.62	53.79	44.45	76.86	66.43	61.80	40.40	21.37	15.95

由表 3.9 可知,MTCF 方法在 BBCsport 和 BBC 数据集上取得了较好的聚类效果,所有的指标值均高于对比方法。在 BBCsport 数据集上,MTCF 方法的聚类 ACC、NMI、ARI 值至少比对比方法的指标值高出了 5.95%、2.5%和 7.59%,比对比方法中的最低指标值高出了 26.4%、38.52%和 32.72%。在 BBC 数据集上,聚类 ACC 值至少比其余对比方法高出 6.23%,NMI 值和 ARI 值至少比对比方法高出 7.47%和 5.38%。MTCF 方法在 Yahoo 数据集上取得了最高为 40.40%的聚类准确率值,但归一化互信息和调整兰德系数的值略低于由深度文本聚类方法 DFTC 得到的值,这可能由特征融合策略难以调节不同视图之间天然的信息冲突。综合来看,相较于对比方法,我们提出的 MTCF 方法表现出了具有竞争力的聚类性能。

3.3 本章总结

本章提出了一种基于视图融合思想的多视图文本聚类模型 MTCF。该模型可利用自编码器结构将预训练语言模型输出的单视图文本嵌入融合为低维、稠密的多视图融合特征。随后在多个数据集上进行了数值实验,研究了数据归一化方法对最终聚类效果的影响,并对所提出模型的多视图融合架构和网络微调策略进行了消融实验,最后在此基础上进行了聚类可视化分析。在实验中,MTCF 方法在多个聚类指标上均高于对比模型,这表明了该方法与基线方法相比具有良好的聚类性能。

由 MTCF 模型最终得到的多视图融合特征对样本多个文本视图下的信息进行了综合,虽然挖掘到了样本中潜藏的不同结构信息,但在融合过程中可能会导致视图信息的损失。因此,在下一章中我们将不对样本的不同视图进行融合,转而考虑利用多

个平行的文本视图下的信息对样本进行动态划分,力求能更大程度的保留和利用多视图文本中的丰富信息。

第四章 基于对比学习的多视图文本聚类模型

在上一章中介绍的基于视图融合的 MTCF 模型虽然在多个数据集上表现良好，但这种将多个视图特征融合生成新的聚类特征的方法可能会破坏原始单视图数据中的流形结构，导致最终的聚类过程难以充分利用样本多个视图中的信息。在本章中，我们将引入对比学习思想，探索一种能最大程度保留和利用单视图文本数据中的自然信息的多视图文本聚类模型。

4.1 模型理论研究

样本不同视图中包含的信息在包含有描述样本自身特性的一致信息的同时，还存在着不同程度的差异。同一样本不同视图中包含的信息可能会在聚类过程中发生冲突，会引导样本进行截然不同的类别划分。因此，我们提出了一种利用对比学习使得多个视图之间互相协同，共同引导最终聚类过程的多视图文本聚类模型 MCCL (Multi-view text Clustering model based on Contrastive Learning)，具体的模型结构如下图所示：




图 4.1 MCCL 模型结构示意图

该模型包含分层特征提取和一致性学习两个模块。在分层特征提取模块中，为避免不同视图中的信息损失，我们将对单视图文本特征分层进行提取和处理，输出对应的单视图特征。在一致性学习模块中，我们设计了具体的损失函数输入单视图特征来学习样本的一致特征和一致标签，最终通过一致标签获得样本的聚类划分。在下文中，我们将对模型的不同模块进行详细介绍。

4.1.1 分层特征提取模块

设数据集集合 $\{T_i^m\} (i=1,2,\dots,n, m=1,2,\dots,M)$ 中包含有 n 个样本在 M 个视图下的文本表示。我们将遵循第三章中 BERT 模型搭配平均特征和层归一化的最佳实验设置进行文本数据的初步嵌入处理,依次输入各个视图下的文本后可得到样本对应的单视图特征,其中所有样本在第 m 个视图下的特征表示为 X^m 。

为进一步提取 BERT 文本嵌入特征中的有效信息并尽可能地对单个视图上的原始数据结构进行保留,我们将在这个模块中为 M 个视图分别搭建自编码器结构。

在自编码器的结构设置中,编码器和解码器的网络结构对称,都堆叠了四层线性变换层和三层激活层。特征首先将被输入至线性变化层进行线性映射,并随后被输入激活层中,重复操作三次后,特征将被输入至最后的线性层中。在线性层和激活层中进行的具体操作如下所示:

$$\tilde{X}^m = BN(W_1 X^m + b_1), \quad (4-1)$$

$$\hat{X}^m = ReLu(\tilde{X}^m). \quad (4-2)$$

我们将第 m 个视图对应的编码器部分记为 $E^m(X^m; \theta^m)$ 。其中, X^m 是被输入的第 m 个视图下的文本特征, θ^m 是可学习的网络参数。该编码器的输出可由下式得到:

$$Z^m = E^m(X^m). \quad (4-3)$$

相应地,我们将第 m 个解码器记为 $D^m(Z^m; \phi^m)$ 。其中,输入 Z^m 为对应编码器的输出, ϕ^m 是网络参数。该解码器的输出可表示:

$$\hat{Z}^m = D^m(Z^m). \quad (4-4)$$

在所有视图上的特征重构损失函数如式(4-5)所示:

$$L_Z = \sum_{m=1}^M L_Z^m = \sum_{m=1}^M \|X^m - \hat{Z}^m\|_2^2. \quad (4-5)$$

在后续实验中我们将根据重构损失函数对所有视图下的自编码器结构进行训练。训练完成后的分层特征提取模块可以学习到高维语义空间到低维语义空间的语义映射,但此时由编码器得到的单视图特征仍可以视为是低层特征。因为不同视图对应的

特征中混合了体现该样本特性的视图一致信息和由于所属视图的天然组织结构差异所携带的视图独有信息。

4.1.2 一致性学习模块

对比学习可以实现表示学习的一致性目标。为了能挖掘低层特征中包含的共同特征并实现最终聚类结果一致性,我们将在这个模块中依次搭建一致特征层和一致标签层,并基于对比学习思想构建对应的损失函数。

对于某一样本来说,其在不同视图下的表现都或多或少地体现了该样本的某一特性。换句话说,我们可以认为样本在不同视图下的特征具有一致性。因此,我们搭建了一致特征层试图通过对比学习方法来挖掘同一样本在不同视图间的一致特征。我们将分层特征提取模块得到的低层特征记为 $Z^m(m=1,2,\dots,M)$,一致特征层记为 $F(\{X^m\}_{m=1}^M;W_H)$,将第 m 个视图下的低层特征 Z^m 输入一致特征层后,根据下式可获得特征 H^m :

$$H^m = F(X^m;W_H). \quad (4-6)$$

从对比学习思想出发,我们将拉近同一样本在不同视图下的特征表示 h_i^m 之间的距离。因此在一致特征层完成训练后,学习到的特征 $\{H^m\}_{m=1}^M$ 可以视为是具有一致性的高层特征。第 m 个视图和第 n 个视图下的样本特征 H^m 和 H^n 之间的对比损失可由下式计算:

$$l_{fc}^{(mn)} = -\frac{1}{N} \sum_{i=1}^N \log \frac{e^{d(h_i^m, h_i^n)/\tau_F}}{\sum_{j=1}^N \sum_{v=m,n} e^{d(h_i^m, h_j^v)/\tau_F} - e^{1/\tau_F}}, \quad (4-7)$$

其中 τ_F 为温度参数, $d(\cdot)$ 为余弦相似度, h_i^m 为第 m 个视图下特征矩阵 H^m 中第 i 个样本对应的特征。在所有视图上的一致特征对比损失 $\mathcal{L}_H$ 如式(4-8)所示:

$$L_H = \frac{1}{2} \sum_{m=1}^M \sum_{n \neq m}^M l_{fc}^{(mn)}. \quad (4-8)$$

在一致特征层后,我们还将搭建一个一致标签层来获得样本在所有视图下的聚类分配。这个一致标签 MLP 记为 $L(\{X^m\}_{m=1}^M;W_Q)$,网络的最后一层将被设置为 softmax 操作来输出第 m 个视图下样本的分配概率矩阵:

$$Q^m = L(X^m;W_Q), \quad (4-9)$$

其中 q_{ij}^m 表示第 i 个样本在第 m 个视图中属于第 j 个簇的概率。

由于需要实现聚类的一致性,即使得所有视图的相同的簇标签都代表相同的语义簇,这就要求在所有视图中样本属于第 j 个簇的概率 $\{Q_j^m\}_{m=1}^M$ 需要保持一致,我们将继续利用对比学习方法来实现这个聚类一致性目标。

第 m 个视图和第 n 个视图下概率矩阵 Q^m 和 Q^n 之间的标签对比损失设置为如下所示:

$$\ell_{lc}^{(mn)} = -\frac{1}{K} \sum_{j=1}^K \log \frac{e^{d(Q_j^m, Q_j^n)/\tau_L}}{\sum_{k=1}^K \sum_{v=m,n} e^{d(Q_j^m, Q_k^v)/\tau_L} - e^{1/\tau_L}}, \quad (4-10)$$

其中 s_j^m 是在第 m 个视图下所有样本被分配到第 j 个簇中的平均概率,即 $s_j^m = \sum_i q_{ij}^m / N$ 。

最终,一致性学习模块的总损失函数 $\mathcal{L}$ 为多视图特征对比损失和聚类一致性损失两部分之和:

$$\begin{aligned} \mathcal{L} &= \mathcal{L}_H + \mathcal{L}_Q \\ &= \mathcal{L}_H \left(\{H^m\}_{m=1}^M; W_H, \{\theta^m\}_{m=1}^M \right) \\ &\quad + \mathcal{L}_Q \left(\{Q^m\}_{m=1}^M; W_Q, \{\theta^m\}_{m=1}^M \right). \end{aligned} \quad (4-11)$$

在模型学习到一致簇分配 $\{Q^m\}_{m=1}^M$ 后,第 i 个样本的最终标签 y_i 由所有视图下的标签层的输出概率 q_{ij}^m 共同决定,单个样本的最终簇分配结果的计算公式如式(4-12)所示:

$$y_i = \operatorname{argmax}_j \left(\frac{1}{M} \sum_{m=1}^M q_{ij}^m \right). \quad (4-12)$$

综上所述,MCCL 模型的算法表如下所示:

表 4.1 基于对比学习的多视图文本聚类算法

算法 4.2: 基于对比学习的多视图文本聚类算法

输入: 多视图文本数据集 $\{T^m\}$; 预训练 epoch 数 Ep_1 ; 对比学习 epoch 数 Ep_2 ; 温度系数

输出: 训练好的模型; 聚类结果

获取初始文本表征 $\{X^m\}$: $X^m = \text{Normlization}(\text{BERT}(T^m))$;

for $i=1$ to Ep_1 **do**

 将单视图文本表征输入对应自编码器进行重构: $\hat{Z}^m = D^m(Z^m) = D^m(E^m(X^m))$;

对分层特征提取模块进行预训练: $L_z = \sum L_z^m = \sum \|X^m - \hat{Z}^m\|_2^2$;

$i = i + 1$;

for $j = 1$ to Ep_2 **do**

获取一致特征 H^m : $H^m = F(X^m; W_H)$;

获取一致标签 Q^m : $Q^m = L(X^m; W_Q)$;

训练一致性学习模块: $L = L_H + L_Q = L_H \left(\{H^m\}_{m=1}^M; W_H, \{\theta^m\}_{m=1}^M \right) + L_Q \left(\{Q^m\}_{m=1}^M; W_Q, \{\theta^m\}_{m=1}^M \right)$;

$j = j + 1$;

end

计算最终预测标签: $y_i = \underset{j}{\operatorname{argmax}} \left(\frac{1}{M} \sum q_{ij}^m \right)$;

计算聚类结果(ACC、ARI、NMI);

输出聚类结果;

4.2 模型实验研究

实验所使用的数据集为 BBCsport、BBC 和 Yahoo 多视图文本数据集,我们从最终聚类效果、消融实验、聚类结果可视化和与经典模型的对比实验四个方面对 MCCL 模型的性能进行了评估。

4.2.1 不同数据集上的实验结果

MCCL 模型中各特征的维度设置如下表所示:

表 4.2 MCCL 模型特征维度设置表

特征名称	特征维度
单视图 BERT 特征	768
单视图低层特征	512
一致性特征	64
一致性标签	同数据集簇数

由 BERT 模型嵌入得到的单视图特征维度为 768,为进行初步的信息提取,我们将各个视图对应编码器输出的低层特征的维度设置为 512。而在一致性学习模块中,一致性特征的维度为 64,一致性标签的维度设置为该数据集的簇数。

数值实验中的句子长度设置同 3.3 节,在 BBCsport 数据集上的 batch_size 设置为 64,其余两个数据集上的 batch_size 设置为 128。温度系数均为 0.5,自编码器的学习率设置为 0.0003,一致特征层和一致标签层上的学习率统一设置为 0.001。我们对编

码器进行预训练的 epoch 数设置为 50，一致性学习模块的 epoch 数设置为 100。为消除随机值带来的影响，我们将在每个数据集上重复进行十五次实验，并将得到的所有指标值进行平均，由此可得到如下表所示的实验结果：

表 4.3 MCCL 模型在不同数据集上得到的聚类指标

	ACC(%)	ARI(%)	NMI(%)
BBCsport	61.98	37.35	30.67
BBC	87.27	69.02	71.72
Yahoo	81.80	65.57	66.45

由表 4.3 可知，我们所提出的模型在 BBCsport 数据集上聚类结果的聚类准确率为 61.98%，归一化互信息值为 37.35%，调整兰德系数为 30.67%；MCCL 模型在 BBC 数据集上的 ACC 值为 87.27%，NMI 值为 69.02%，ARI 值为 71.72%；而在 Yahoo 数据集上得到的三个指标值分别为 81.80%、65.57%和 66.45%。

4.2.2 消融实验

为从多个角度检验所提出的 MCCL 模型各部分架构的有效性，我们将从自编码器、一致特征层和一致标签层三个部分对最终聚类的性能影响进行验证。

在对自编码器结果的有效性进行验证时，我们将去掉自编码器部分，保留 MCCL 模型的其它部分结构不变；并将一致特征层的输入维度修改为 768，以便将 BERT 嵌入特征直接输入至一致特征层中进行后续聚类。

表 4.4 有无自编码器结构的聚类性能对比

	BBCsport			BBC			Yahoo		
	ACC	NMI	ARI	ACC	NMI	ARI	ACC	NMI	ARI
无自编码器	54.68	35.39	27.80	79.30	63.37	60.87	77.96	64.90	63.23
有自编码器	61.98	37.35	30.67	87.27	69.02	71.72	81.80	65.57	66.45

表 4.4 为有无自编码器进行低层特征提取和特征复原时，MCCL 模型在不同数据集上的聚类指标数值。从表中我们可以直观的看到当保留自编码器结构时，模型的在同一数据集上聚类结果的聚类准确率、归一化互信息和调整兰德系数都高于没有自编码器时，这表明了 MCCL 模型中自编码器结构的有效性。具体来说：在 BBCsport 数据集上，有自编码器结构时聚类 ACC、NMI、ARI 值比没有自编码器结构时高出了 7.3%、1.96%和 2.87%。在 BBC 数据集上，保留自编码器结构时，聚类结果的 ACC

值提高了 7.97%，NMI 值提高了 5.65%，ARI 值提高了 10.85%。而在 Yahoo 数据集上，保留自编码器结构时三个聚类指标值分别提高了 3.84%、0.67%和 3.22%。

我们对编码器得到的低层特征和一致特征层得到的高层特征同时使用 K-Means 方法进行聚类，由此验证一致标签层是否学习到了性能更好的高层特征。在 BBCsport、BBC 和 Yahoo 数据集上得到的聚类指标数值如表 4.5 所示：

表 4.5 MCCL 模型不同维度特征的聚类性能

	BBCsport			BBC			Yahoo		
	ACC	NMI	ARI	ACC	NMI	ARI	ACC	NMI	ARI
低层特征 v1	58.34	34.96	27.35	76.67	62.75	61.72	58.59	51.32	38.83
高层特征 v1	61.22	37.12	30.77	83.96	65.99	67.73	76.40	64.55	62.90
低层特征 v2	62.14	39.87	31.04	83.70	68.21	69.47	54.99	43.27	24.53
高层特征 v2	61.71	37.91	31.05	85.53	68.24	69.78	71.46	58.28	56.68




图 4.2 不同维度特征的 BBCsport 聚类指标比较图




图 4.3 不同维度特征的 BBC 聚类指标比较图




图 4.4 不同维度特征的 Yahoo 聚类指标比较图

图 4.2、图 4.3、图 4.4 分别是在 BBCsport、BBC 和 Yahoo 三个数据集上由不同视图的低层特征和高层特征得到的聚类结果各项指标的柱状图。根据图表可知：

1.在 BBCsport 数据集上，视图一的一致性高层特征的聚类 ACC、NMI、ARI 值比低层特征分别高出 2.88%、2.16%和 3.42%；视图二的高层特征聚类结果的 ARI 值相比低层特征有所提升，但 NMI 值和 ARI 值略低于低层特征，可能是由于 BBCsport 数据集的数据量较小，难以为模型的对比学习策略提供足量的数据支撑。

2.在 BBC 数据集上，相比直接由编码器得到的低层特征，由一致特征层得到的视图一的高层特征在聚类 ACC、NMI、ARI 指标值上分别提升了 7.29%、3.24%和 6.01%，视图二的高层特征在三个指标值上分别提升了 1.83%、0.03%和 0.31%。

3.在 Yahoo 数据集中，一致特征层给各个视图特征的聚类指标带来了较大提升。其中，视图一特征的 ACC 值提升了 11.85%，NMI 值提升了 13.23%，ARI 值提升了 24.07%；视图二特征的 ACC 值提升了 16.47%，NMI 提升了 15.01%，ARI 值提升了 32.15%。

在多个指标集上，一致特征层生成的高层特征比仅使用编码器生成的低层特征表现出了更好的聚类性能，由此可证明一致特征层的有效性。该部分利用对比学习思想，可以拉近特征空间中同一样本不同视图表示之间的距离，因此能比低层特征更好地指导后续的聚类过程。

在研究一致特征层有效性的消融实验中，我们首先删除一致特征层，将一致特征层产生的样本不同视图的高层特征进行平均，并使用 K-means 方法进行最终聚类。最后将删除掉一致特征层的实验结果与保留一致特征层时的各项聚类指标进行对比，据此来检验一致特征层是否协调了聚类过程中不同视图的的聚类分区导向，表 4.6 为我们实验得到的。


表 4.6 有无标签层的聚类性能对比

	BBCsport			BBC			Yahoo		
	ACC	NMI	ARI	ACC	NMI	ARI	ACC	NMI	ARI
无一致标签层	54.41	32.58	26.08	82.02	61.43	61.84	75.52	63.31	58.90
有一致标签层	61.98	37.35	30.67	87.27	69.02	71.72	81.80	65.57	66.45


由上表可知,在所有数据集中有一致标签层时,各项聚类指标均高于删掉一致标签层直接进行聚类时得到的指标。在 BBCsport 数据集上,一致标签层为最终的聚类结果在 ACC 值上带来了 7.57%的提升,在 NMI 值上带来了 4.77%的提升,在 ARI 值上带来了 4.59%的提升。在 BBC 数据集上一致标签层为聚类结果的 ARI 值带来的提升幅度最大,为 9.88%,为 ACC 值和 NMI 值分别带来了 5.25%和 7.59%的提升。而在 Yahoo 数据集上,有无一致标签层设置让聚类结果的 ACC、NMI 和 ARI 指标值相差了 6.28%、2.26%和 7.55%。不难看出,一致标签层对同一样本不同视图所对应的标签进行了协调和统一,使得更多的样本能被正确的划分,提升了最终的聚类效果。

4.2.3 可视化实验


为能更直观的体现出各类特征的聚类性能,我们将对 Yahoo 数据集和 BBC 数据下的样本各个视图的 BERT 嵌入特征、低层特征和高层特征使用 T-SNE 方法进行可视化。




(a) 视图一 BERT 特征聚类结果可视化



(b) 视图二 BERT 特征聚类结果可视化



(c) 视图一低层特征聚类结果可视化



(d) 视图二低层特征聚类结果可视化





图 4.5 Yahoo 数据集不同维度特征的可视化结果

在图 4.5 中, (a)、(c)、(e)分别为 Yahoo 数据中视图一对应的 BERT 嵌入、低层特征和高层特征, (b)、(d)、(f)为视图二对应的三种特征。在(a)和(b)所代表的原始 BERT 嵌入中, 我们可以看到代表着不同真实类别的不同颜色的样本点排布散乱。其中, 政治经济类别所代表的紫色样本点尤其的零散, 夹杂在其他颜色的样本点中。在(c)和(d)所代表的低层特征可视化的图中, 与原始嵌入相比, 不同样本簇之间的距离增大, 分界较为清晰。这从另一面反应了编码器可以对原始特征嵌入进行了过滤, 由此得到的低层特征更能体现样本的特质。在(e)、(f)这两幅图中, 相同颜色的样本分布更加集中, 形成了色块, 与此同时不同色块之间的距离进一步拉大, 分界也更加明显。






图 4.6 BBC 数据集不同维度特征的可视化结果

在图 4.6 中, (a)和(b)分别是由 BBC 数据集的原始 BERT 嵌入得到的可视化散点图。在图(a)中除商业所代表的红色样本点相对较为集中以外, 其余四类样本点混杂在一起。由于 BBC 数据集不同视图包含的信息量不均匀, (b)中不同色的样本点相较(a)中有大致的分区, 但不同簇的分界边缘不明显。(c)、(d)为由低层特征对应的可视化图, 此时样本点分布有成团状的趋势, 不同颜色的样本簇在形状上有了一定的区分度, 但部分如(c)中红色和绿色的样本簇一样仍互相连同。而在(e)、(f)所代表的高维特征中, 相同颜色的样本点被进一步拉近, 不同类别的样本簇之间分界清晰且距离较远, 表示此时样本点之间具有较高的区分度。

4.2.4 与经典模型的比较

我们将 MCCL 与六种方法进行对比, 其中 Tf-idf+KM 为基线方法, LDA、GSDMM、STC 和 DFTC 为经典的文本聚类方法, 而 MTCF 为我们在第三章提出的一种基于视图融合的多视图文本聚类方法。

表 4.7 MCCL 模型与对比方法的聚类性能比较

	BBCsport			BBC			Yahoo		
	ACC	NMI	ARI	ACC	NMI	ARI	ACC	NMI	ARI
TF-idf+KM	58.25	46.51	28.29	48.14	39.06	20.06	32.93	18.24	11.82
LDA	41.22	15.27	11.73	40.30	15.32	10.92	24.66	12.94	10.25
GSDMM	52.18	33.74	27.45	67.54	46.68	46.15	37.84	23.98	19.18
STC	57.80	51.29	36.86	58.07	51.20	36.82	35.24	22.93	12.98
DFTC	61.67	39.06	29.52	70.63	58.96	56.42	39.45	24.34	19.92
MTCF(ours)	67.62	53.79	44.45	76.86	66.43	61.80	40.40	21.37	15.95
MCCL(ours)	61.98	37.35	30.67	87.27	69.02	71.72	81.80	65.57	66.45




图 4.7 MCCL 与经典方法的 BBCsport 聚类指标对比图




图 4.8 MCCL 与经典方法的 BBC 聚类指标对比图




图 4.9 MCCL 与经典方法的 Yahoo 聚类指标对比图

由表 4.5 和图 4.7~4.9 中的实验数据可知, 在 BBC 数据集和 Yahoo 数据集上, MCCL 方法取得了最好的聚类结果, 在 ACC、NMI 和 ARI 指标上均为最高。在 BBC 数据集上, MCCL 方法取得的 ACC 值为 87.27%, 比其余方法至少高出 10.41%, NMI 值至少比其他方法高出 2.59%, ARI 值至少比其余六种方法高出 9.92%。在 Yahoo 数据集上本章提出的 MCCL 方法表现最为突出, 其 ACC、NMI、ARI 值至少比其余六种方法高出 41.4%、41.23%和 46.53%。在 BBCsport 数据集上表现最好的方法是第三章提出的 MTCF 方法, MCCL 方法表现不太理想的原因可能和 BBCsport 数据量较小有关。

4.3 本章总结

在本章中, 我们提出了一种的更加灵活的多视图文本聚类模型 MCCL。在分区特征提取模块中, MCCL 对不同视图下的文本分别建立自编码器结构进行特征提取, 以保留各个视图的原始数据结构和视图独有信息; 在一致性学习模块中, 我们利用对比学习思想协同多个视图下的特征进行一致特征层和一致标签层的网络训练。样本最终的聚类标签将由所有视图下的特征共同决定, 并由一致标签层输出。

通过在数据集上进行实验可知, 相较于传统的文本聚类方法, 我们的方法相在多个性能指标上都有较大的提升。特别是在 Yahoo 数据集上, 我们的方法带来了显著的聚类性能提升。我们这种分层结构的设计实现了特征空间的有效整合, 有利于寻找最优的聚类目标。而对比学习的引入, 使得模型能够更全面地捕捉文本数据中的一致信息和视图特有信息, 从而提高了特征在聚类任务中的判别性。

第五章 总结与展望

5.1 本文工作总结

在数据传播形式和存在形式逐渐多视图化的今天,如何管理和归类大量数据是众多学者所关心的问题。在席卷我们日常生活的庞大数据流中,文本数据可谓是占据了半壁江山。人们日常的工作、学习、娱乐和社交都离不开语言文字。因此本文面向具有多视图结构的文本数据,研究了如何更好地在聚类任务中从样本的不同视图提取聚类特征后联合多个视图特征引导样本进行高质量的划分。由于,具有出色性能的预训练语言模型在众多自然语言处理任务中都获得了突出的成果。我们在聚类任务中引入了预训练语言模型进行初步的文本表征提取。针对多视图文本的特殊结构,我们从模型理论和数值实验两部分进行了多视图文本聚类模型的研究。具体的研究内容主要有以下两个方面:

1.创新性地提出了一种基于特征融合框架的多视图文本聚类模型 MTCF。本方法在使用预训练模型 BERT 获取初步文本特征的基础上,利用自编码器结构设计了一种多视图特征融合框架,以进一步综合不同视图中的信息,提高对文本特性的表示能力。在对这一架构进行预训练后,我们将搭建语义聚类层并对所有网络和簇中心进行微调。实验结果表明,我们通过多视图特征融合框架得到的融合特征具有全局性认知,在所有数据集上表现出的聚类性能均优于单视图特征和视图拼接特征;语义聚类模块设置的网络微调策略则进一步引导了样本形成良好的聚类分区。与经典的文本聚类方法相比, MTCF 模型在 BBC、BBCsport 及 Yahoo 数据集上的聚类结果在聚类准确率、归一化互信息和调整兰德系数三个指标上均有一定提升,体现出良好的性能。

2.为尽可能多地保留不同视图中的信息,避免特征融合方法带来的信息损失,本文提出了一种基于对比学习的分层式多视图文本聚类模型 MCCL。该模型为不同视图的文本分别建立了深度特征提取器,这种分层式的处理方法可以灵活地调整每个视图下的特征表示,保留不同视图下具有的数据分布和特性。在为单视图特征建立的一致特征提取层和一致标签层上,我们利用对比学习思想拉近了同一样本在不同视图下的特征表示之间的距离,并尽可能的实现不同视图上的聚类结果的一致性。在多个数据集上的数值实验和可视化实验进一步表明了 MCCL 模型各部分结构设计的合理性和优越性。除此之外,我们的方法在诸多对比方法都表现平平的 Yahoo 数据集上捕捉到了各个视图数据中隐藏的集群信息,实现了较理想的聚类结果。

5.2 本文工作展望

本文迎合当今数据多视图化的主流趋势,为多视图文本聚类任务设计了具体的算法模型。特征提取和下游任务模型是深度学习方法的并驾齐驱的两大主线,我们将围绕这两个主题继续对多视图文本聚类模型进行优化和改进。在未来,我们有可能从以下方面继续进行研究:

1.尝试利用其他预训练语言模型提取文本特征。在本文中,我们利用了最经典的 BERT 模型对样本各个视图的特征进行初步提取。而在自然语言处理领域中陆续涌现出了一系列基于 BERT 等模型改进的预训练模型,这些模型进一步发掘了文本的隐含表示,提升了在各类任务上的效果。因此在之后的工作中,我们可以尝试使用其他模型继续进行实验。

2.利用对比学习方法对预训练语言模型进行微调。由于预训练模型只学习到了预训练语料中的综合知识,模型输出的特征并不一定吻合下游的具体任务需求,因此我们将考虑利用对比学习这类无监督方法对预训练好的模型参数进行微调。

3.研究具有不需要人工指定簇数的多视图文本聚类模型。传统对的聚类方法通常需要用户预先指定簇的个数,这在实际应用中是有实现门槛的,因为簇的个数往往是难以确定的。在未来的研究中我们可以加入预估数据集中簇总数的模块,使其更加具有灵活性和实用性。

4.增强多视图文本聚类模型的可解释性。为了使得文本多视图聚类模型在实际应用中得到广泛接受,模型的可解释性至关重要。我们可以将进一步研究具体的模型结构,使其兼具良好的聚类性能和可解释性,这也能帮助我们更好地理解模型的内在机制。

参考文献

- [1] GEORGE A. MILLER. WordNet: A lexical database for English[J]. Communications of the ACM, 1995, 38(11): 39-41.
- [2] DCERWESTER S, DUMAIS T, FURNAS W, et al. Indexing by latent semantic analysis[J]. Journal of the American Society for Information Science, 1990, 41(6): 391-407.
- [3] BENGIO Y, DUCHARME R, VINCENT P, et al. A neural probabilistic language model[J]. The Journal of Machine Learning Research. 2003, 3(3): 1137-1155.
- [4] MIKOLOV T, CHEN K, CORRADO G, et al. Efficient estimation of word representations in vector space[J]. Computer Science. 2013(1): 1-12.
- [5] PENNINGTON J, SOCHER R, MANNING C. Glove: Global vectors for word representation[C]//Proceedings of the 2014 Conference on Empirical methods in Natural Language Processing. Stroudsburg: ACL. 2014: 1532-1543.
- [6] MATTHEW E. PETERS. Deep contextualized word representations[C]//Proceedings of the North American Chapter of the Association for Computational Linguistics. Stroudsburg, PA: ACL. 2018: 2227-2237.
- [7] RADFORD A, NARASIMHAN K, SALIMANS T, et al. Improving language understanding by generative pre-training[J]. arXiv preprint arXiv: 1301. 3781, 2018.
- [8] JACOB D, CHANG M, LEE K, et al. BERT: Pre-training of deep bidirectional transformers for language understanding[C]//Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies. Stroudsburg. PA: ACL. 2019: 4171-4186.
- [9] LIU Y, OTT M, GOYAL N, et al. RoBERTa: A robustly optimized BERT pretraining approach[J]. arXiv preprint arXiv: 1907. 11692, 2019.
- [10] L E, Z LAN, P SHARMA, et al. ALBERT: A lite BERT for self-supervised learning of language representations[J]. arXiv preprint arXiv: 1909. 11942, 2019.
- [11] CLARK K, LUONG M T, LE Q V, et al. ELECTRA: Pre-training text encoders as discriminators rather than generators[J]. ICLR, 2020. 2019.
- [12] HARTIGAN J A, WONG M A. Algorithm AS 136: A k-means clustering algorithm[J]. Journal of the Royal Statistical Society. Series c (Applied Statistics). 1979, 28(1): 100-108.
- [13] ARTHUR D, VASSILVITSKII S. K-Means++: The advantages of careful seeding[C]//Proceedings of the eighteenth annual ACM-SIAM symposium on Discrete algorithms. pA, USA: Society for Industrial and Applied Mathematics. 2007.

- [14] KRISHNAPURAMR, JOSHIA, YI L. A fuzzy relative of the K-me-doids algorithm with application to web document[C]//Fuzzy Systems Conference Proceedings. 1999: 1281-1286.
- [15] FREDANA, ANIL K, JAIN, et al. Evidence accumulation clustering based on the K-means algorithm[C]//9th International Workshop on Structural and Syntactic Pattern Recognition (SSPR 2002) and the 4th International Workshop on Statistical Techniques in Pattern Recognition (SPR 2002), 2002: 442-451.
- [16] HU J, FANG L, CAO Y, et al. Enhancing text clustering by leveraging wikipedia semantics[C]//Singapore: Proceedings of the 31st Annual International ACM SIGIR Conference on Research and Development in Information Retrieval, 2008.
- [17] HOFMANN T. Unsupervised learning by probabilistic latent semantic analysis[J]. Machine Learning, 2001, 42(1-2): 177-196.
- [18] D M. BLEI, A Y NG, M I. JORDAN. Latent dirichlet allocation[J]. Proceeding of the Journal of Machine Learning Research. 2003, 3: 993-1022.
- [19] YIN J, WANG J A. Dirichlet multinomial mixture model-based approach for short text clustering[C]//Proceedings of the 20th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining. NY: Association for Computing Science. 2014: 233-242.
- [20] KINGMA D P, WELLING M. Auto-encoding variational bayes[C]//International Conference on Learning Representations. Ithaca, NYarXiv.org, 2013.
- [21] ZHANG D, SUN Y, ERIKSSON B, et al. Deep unsupervised clustering using mixture of autoencoders [EB/OL]. (2017-12-26) [2022-9-25].
- [22] JIANG Z, ZHENG Y, TAN H, et al. Variational deep embedding: an unsupervised and generative approach to clustering [EB/OL]. (2017-06-28) [2022-09-25].
- [23] BISHOP C. Pattern recognition and machine learning[M]. New York: Springer New York, 2006.
- [24] HINTON G E, SALAKHUTDINOV R R. Reducing the dimensionality of data with neural networks[J]. Science, 2006, 313(5786): 504-507.
- [25] XIE J, GIRSHICK R, FARHADIAI A. Unsupervised deep embedding for clustering analysis[C]// Proceedings of the 33rd International Conference on International Conference on Machine Learning. New York: PMLR, 2016: 478-487.
- [26] RAIBER F, KURLAND O. Kullback-leibler divergence revisited[C]//Proceedings of the ACM SIGIR International Conference on Theory of Information Retrieval. New York: ACM 2017: 117-124.
- [27] BO D, WANG X, SHI C, et al. Structural deep clustering network[C]//Proceedings of the 2020 Web Conference. New York: ACM. 2020: 1400-1410.
- [28] XU J, XU B, WANG P, et al. Self-taught convolutional neural networks for short text clustering[J].

- Proceeding of the Neural Networks. 2017, 88: 22-31.
- [29] AMIR H, LUCAS S THOMAS D, et al. A self-training approach for short text clustering[C]//Proceedings of the 4th Workshop on Representation Learning for NLP. STROUDSBURG, PA: ACL. 2019: 194-199.
- [30] SANJEEV A, YING L, TENG M. A simple but tough-to-beat baseline for sentence embeddings[C]//Proceedings of the International Conference on Learning Representations. Ithaca, NY: OpenReview.net. 2017.
- [31] GUAN R, ZHANG H, LIANG Y, et al. Deep feature-based text clustering and its explanation[J]. Proceeding of the IEEE Transactions on Knowledge and Data Engineering. 2022, 34(8): 3669-3680.
- [32] CONNEAU A, KIELA D, SCHWENK L H, et al. Supervised learning of universal sentence representations from natural language inference data[C]//Proceedings of the 2017 Conference on Empirical Methods in Natural Language Processing. Stroudsburg: ACL. 2017: 670-680.
- [33] HOTELLING H. Relations between two sets of variates[J]. Biometrika, 1936, 28(3/4), 321-377.
- [34] AKAHO S. A kernel method for canonical correlation analysis[EB/OL]. (2007-02-14) [2022-03-02].
- [35] BENTON A, KHAYRALLAH H, GUJRAL B, et al. Deep generalized canonical correlation analysis[C]//Proceedings of the 4th Workshop on Representation Learning for NLP. Florence, Italy: Association for Computational Linguistics. 2019: 1-6.
- [36] LEE C, SCHAAR M. A variational information bottleneck approach to multi-omics data integration[C]//Proceedings of the 24th International Conference on Artificial Intelligence and Statistics. NY: PMLR. 2021: 1513-1521.
- [37] BLUM A, MITCHELL T. Combining labeled and unlabeled data with co-training[C]//European Symposium Artificial Neural Networks. Bruges: Belgium. 1998: 92-100.
- [38] WANG H, YANG Y, LIU B. GMC: Graph-based multi-view clustering[J]. IEEE Transactions on Knowledge and Data Engineering. 2020, 32(6): 1116-1129.
- [39] ZHENG Q, ZHU J, LI Z, et al. Graph-guided unsupervised multiview expression learning[J]. IEEE Transactions on Circuits and Systems for Video Technology. 2023, 33(1): 146-159.
- [40] BENNETT K, MOMMA M, EMBRECHTS M. MARK: A boosting algorithm for heterogeneous kernel models[C]//Knowledge Discovery and Data Mining. Alberta: Canada, 2002: 1-8.
- [41] SONNENBURG S, RÄTSCH G, SCHÄFER C. Large scale multiple kernel learning [J]. Journal of Machine Learning Research. 2006, 7: 1531-1565.
- [42] DAVID E. RUMELHART, JANMES L. MCCLELLAND, et al. Parallel distributed processing: explorations in the microstructure of cognition[M]. Cambridge: MIT Press, 1986.

- [43] NG A. Sparse autoencoder[J]. CS294A Lecture Notes, 2011, 72(1): 1-19.
- [44] KINGMA D P, WELLING M. Auto-encoding variational bayes[J]. arXiv Preprint, arXiv: 1312.6114, 2013.
- [45] VINCENT P, LAROCHELLE H, LAJOIE I, et al. Stacked denoising autoencoders: learning useful representations in a deep network with a local denoising criterion[J]. Journal of Machine Learning Research, 2010, 11(12): 3371-3408.
- [46] GUO X, GAO L, LIU X, et al. Improved deep embedded clustering with local structure preservation[J]. Joint Conference on Artificial Intelligence, 2017, 7: 1753-1759.
- [47] VASWANI A, SHAZEER N, PARMAR N, et al. Attention is all you need[J]. Advances in Neural Information Processing Systems. 2017, 30.
- [48] SCHUSTER M, PALIWAL K K. Bidirectional recurrent neural networks[J]. IEEE Transactions on Signal Processing. 1997, 45(11): 2673-2681.
- [49] LECUN Y, BOTTOU L, BENGIO Y, et al. Gradient-based learning applied to document recognition[J]. Proceedings of the IEEE. 1998, 86: 2278-2324.
- [50] ASHWIN G, IRINA I, DOMINIQUE F. Bert and fasttext embeddings for automatic detection of toxic speech[C]//International Multi-Conference on: "Organization of Knowledge and Advanced Technologies" (OCTA). New York: IEEE. 2020: 1-5.
- [51] YE Z, JIANG G, LIU Y, et al. Document and word representations generated by graph convolutional network and BERT for short text classification[C]//European Conference on Artificial Intelligence. Santiago de Compostela, SPAIN: IOS Press. 2020, 325: 2275-2281.
- [52] YU Q, WANG Z, JIANG K. Research on text classification based on bert-bigru model[J]. Phys Conf Series. 2021, 1746: 12-19.
- [53] SHI H, WANG C. Self-supervised document clustering based on bert with data augment[J]. arXiv preprint arXiv: 2011.08523, 2020.
- [54] UBAKTI A, MURFI H, HARIADI N. The performance of BERT as data representation of text clustering[J]. Big Data. 2022, 9(1): 15.
- [55] CHEN T, KORNBLITH S, NOROUZI M, et al. A simple framework for contrastive learning of visual representations[C]//25th Americas Conference on Information Systems of the Association for Information Systems. Atlanta, GA: Assoc Information Systems. 2020: 1597-1607.
- [56] HE K, FAN H, WU Y, et al. Momentum contrast for unsupervised visual representation learning[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. Piscataway: IEEE Computer Society. 2020: 9729-9738.
- [57] GRILL J B, STRUB F, ALTCHÉ F, et al. Bootstrap your own latent-a new approach to self-supervised learning[J]. Advances in Neural Information Processing Systems. Cambridge, MA:

- MITPress. 2020, 33: 21271-21284.
- [58] CHEN X, HE K. Exploring simple siamese representation learning[C]//Proceedings of the IEEE/ CVF Conference on Computer Vision and Pattern Recognition. Piscataway: IEEE Computer Society. 2021: 15750-15758.
- [59] GAO T, YAO X, CHEN D. SimCSE: Simple contrastive learning of sentence embeddings[C]//In Proceedings of the 2021 Conference on Empirical Methods in Natural Language Processing. Stroudsburg: ACL. 2021: 6894-6910.
- [60] YAN Y, LI R, WANG S, et al. ConSERT: A contrastive framework for self-supervised sentence representation transfer[J]. arXiv preprint arXiv: 2105. 11741, 2021.
- [61] ZHANG Y, ZHU H, WANG Y, et al. A contrastive framework for learning sentence representations from pairwise and triple-wise perspective in angular space[C]//In Proceedings of the 60th Annual Meeting of the Association for Computational Linguistics. Dublin, Ireland: Association for Computational Linguistics. 2022, 1: 4892-4903.
- [62] GIORGI J M, NITSKI O, BADER G D, et al. DeCLUTR: Deep contrastive learning for unsupervised textual representations[C]//In Proceedings of the 59th Annual Meeting of the Association for Computational Linguistics and the 11th International Joint Conference on Natural Language Processing. Stroudsburg: ACL. 2021: 879-895.